

**Escuela Técnica Superior de Ingeniería
Universidad de Huelva**

Grado en Ingeniería Informática

Trabajo Fin de Grado

Detección de Misoginia en Letras de Canciones mediante
Large Language Models (LLMs)

Antonio Toro Jaén

Victoria Pachón Álvarez

Jacinto Mata Vázquez

marzo, 2025

Resumen

La misoginia es un problema social que está presente en las interacciones personales y en la cultura, incluyendo la música. A lo largo del tiempo, numerosas canciones han incluido discursos sexistas que pueden contribuir a la normalización de la discriminación y la violencia de género. La música tiene un impacto significativo en la percepción y construcción de la realidad social, por lo que la presencia recurrente de mensajes misóginos en las letras de canciones puede reforzar estereotipos de género perjudiciales, legitimar actitudes sexistas y perpetuar dinámicas de desigualdad.

Este Trabajo de Fin de Grado se centra en el desarrollo de un sistema de clasificación automática de letras de canciones en español, aplicando técnicas avanzadas de Deep Learning y Procesamiento del Lenguaje Natural (PLN). El proyecto aborda dos tareas distintas: en primer lugar, la detección binaria de discursos misóginos, es decir, identificar si una letra contiene o no contenido de este tipo; y en segundo lugar, la clasificación del tipo de misoginia presente en caso de detección positiva, diferenciando entre categorías como sexualización, violencia, odio o contenido no relacionado.

Para abordar estas tareas se utilizarán Grandes Modelos de Lenguaje, más conocidos como Large Language Models (LLM). Estos modelos, conocidos por su gran volumen de datos y complejidad, son capaces de analizar y contextualizar con gran precisión los mensajes para resolver este tipo de tareas.

Para finalizar, se procederá al análisis de los resultados obtenidos, con el propósito de demostrar la eficacia de los modelos para identificar con precisión el lenguaje misógino. La validación de este desempeño se realizará en el contexto de la competición MySonGyny, permitiendo una comparación con otras técnicas empleadas en la misma tarea.

Palabras clave: Misoginia, Procesamiento del Lenguaje Natural, Deep Learning, Large Language Models, Música.

Abstract

Misogyny is a social issue present in personal interactions and culture, including music. Over time, numerous songs have featured sexist discourse that may contribute to the normalization of discrimination and gender-based violence. Music has a significant impact on the perception and construction of social reality, so the recurrent presence of misogynistic messages in song lyrics can reinforce harmful gender stereotypes, legitimize sexist attitudes, and perpetuate dynamics of inequality.

This Bachelor's Thesis focuses on the development of an automatic classification system for Spanish song lyrics, applying advanced techniques in Deep Learning and Natural Language Processing (NLP). The project addresses two distinct tasks: first, the binary detection of misogynistic discourse, i.e., identifying whether a lyric contains such content or not; and second, the classification of the type of misogyny present in case of a positive detection, distinguishing between categories such as sexualization, violence, hate, or unrelated content.

To tackle these tasks, Large Language Models (LLMs) will be used. These models, known for their vast data volume and complexity, are capable of analyzing and contextualizing messages with high accuracy to solve this kind of task.

Finally, the results obtained will be analyzed in order to demonstrate the effectiveness of the models in accurately identifying misogynistic language. The performance will be validated in the context of the MySonGyny competition, allowing for comparison with other techniques used for the same task.

Keywords: Misogyny, Natural Language Processing, Deep Learning, Large Language Models, Music.

Agradecimientos

Quiero comenzar agradeciendo a todos los profesores que me han acompañado a lo largo de mi trayectoria académica, por despertar en mí la curiosidad y el deseo constante de aprender. También a mis tutores, por su compromiso y por compartir su conocimiento con tanta dedicación.

A mis compañeros, por estar presentes en el camino, por el apoyo mutuo y por los momentos compartidos.

Y, por supuesto, a mi familia, por su paciencia, su cariño y por creer en mí en cada etapa.

Antonio Toro Jaén

Huelva, 2025

Índice general

Resumen	I
Abstract	II
Agradecimientos	III
Índice de Figuras	VI
Índice de Tablas	VII
1. Introducción	1
1.1. Motivación	1
1.2. Objetivos	2
1.3. Competencias	2
1.4. Estructura de la memoria	3
2. Marco Teórico	5
2.1. Aprendizaje Automático	5
2.1.1. Tipos de Aprendizaje	5
2.2. Clasificación de textos	6
2.3. Aprendizaje profundo	7
2.3.1. Épocas	7
2.3.2. Tamaño del lote	8
2.3.3. Tasa de aprendizaje	9
2.3.4. Detención temprana	9
2.4. Modelos de lenguaje actuales	10
2.4.1. Características comunes	10
2.4.2. Modelos Representativos	11
2.5. Procesamiento del Lenguaje Natural	12
2.5.1. Preprocesamiento del texto	12
2.5.2. Representación del texto	13
2.5.3. Tipos de prompting en LLMs	14
2.6. Aprendizaje por Transferencia	15
2.6.1. Fine-tuning y optimización de hiperparámetros.	16
2.6.2. LoRA	16
2.7. Ensemble de modelos	16
2.8. Medidas de Evaluación	17
2.9. Trabajos relacionados	19
2.10. Tecnologías y recursos utilizados	22
3. Metodología, Experimentación y Resultados	23
3.1. Participación en un reto	23
3.2. Descripción de la metodología	24
3.3. Análisis de los datos	26
3.4. Preprocesamiento de los datos	28
3.4.1. Cadenas de pensamiento (Chain of Thought)	30

3.5.	Selección de modelos	31
3.6.	Ajuste de hiperparámetros	31
3.6.1.	Hiperparámetros Evaluados	32
3.6.2.	Criterios de selección	32
3.7.	Entrenamiento de los modelos	32
3.7.1.	Entrenamiento con Longformer	33
3.7.2.	Entrenamiento con Cadenas de Pensamiento CoT (DeepSeek R1) . .	33
3.7.3.	Entrenamiento con Qwen y LLaMA	35
3.8.	Análisis de resultados	38
3.8.1.	Resultados de Clasificación binaria	38
3.8.2.	Resultados de Clasificación multiclase	40
3.8.3.	Matrices de confusión	41
3.8.4.	Ensemble	47
3.9.	Análisis de errores	49
3.9.1.	Errores en Clasificación binaria	49
3.9.2.	Errores en Clasificación multiclase	49
3.10.	Resultados Oficiales de la Tarea	50
3.10.1.	Publicación de resultados	51
4.	Conclusiones y Trabajo Futuro	52
4.1.	Conclusiones	52
4.1.1.	Resumen de los Hallazgos	52
4.1.2.	Contribuciones y Consideraciones Éticas	53
4.2.	Trabajo Futuro	53
4.3.	Planificación Temporal del Trabajo Realizado	54
	Referencias	55
A.	Anexos	58
A.1.	Repositorio de código en GitHub y modelos en Hugging Face	58
A.2.	Aplicación Web para la Visualización y Prueba del Modelo	59
A.3.	Paper de la Competición MiSonGyny	61

Índice de Figuras

2.1. Tipos de aprendizaje automático [7]	6
2.2. El equilibrio del Aprendizaje [10]	8
2.3. Batch Sizes [11]	8
2.4. Early Stopping [14]	9
2.5. Ejemplo de embeddings	13
2.6. Esquema de funcionamiento del ensemble por votación mayoritaria.	17
2.7. Matriz de confusión [30]	19
3.1. Esquema general del pipeline seguido en este trabajo. Se representa el flujo completo desde la preparación de los datos y la generación de cadenas de razonamiento, hasta el entrenamiento, evaluación y combinación de modelos mediante ensemble.	25
3.2. Distribución de la longitud de letras de canciones en el conjunto de datos.	26
3.3. Top 20 palabras con mayor diferencia de frecuencia en letras etiquetadas como misóginas.	27
3.4. Top 20 palabras con mayor diferencia de frecuencia en letras clasificadas como no misóginas.	27
3.5. Distribución de clases en el conjunto de datos de la Tarea 1.	28
3.6. Distribución de clases en el conjunto de datos de la Tarea 2.	29
3.7. Eval loss durante el entrenamiento del modelo DeepSeek-R1	34
3.8. Eval loss durante el entrenamiento de los modelos Qwen3 y LLaMA 3.1	37
3.9. Matriz de confusión del modelo Longformer (Tarea 1).	41
3.10. Matriz de confusión del modelo DeepSeek R1 con CoT por GPT4o (Tarea 1).	42
3.11. Matriz de confusión del modelo DeepSeek R1 con CoT por Salamandra (Tarea 1).	43
3.12. Matriz de confusión del modelo LLaMA 3.1 8B con Prompt Simple (Tarea 1).	44
3.13. Matriz de confusión del modelo Qwen3 8B con Prompt Simple (Tarea 1).	45
3.14. Matriz de confusión del modelo Qwen3 8B Prompt Detallado (Tarea 1).	46
3.15. Matriz de confusión del modelo Qwen3 8B Prompt Simple (Tarea 2).	47
A.1. Captura de pantalla de la App	60

Índice de Tablas

2.1. Ejemplo de preprocesamiento del texto de una canción.	13
3.1. Ejemplo de letra original y resultado tras aplicar normalización y limpieza de texto.	30
3.2. Resultados globales (clasificación binaria) en el conjunto de test.	38
3.3. Resultados por clase para los modelos evaluados (conjunto de test, Tarea 1).	39
3.4. Resultados globales (macro-average) del modelo evaluado en la Tarea 2.	40
3.5. Resultados por clase para el modelo evaluado (Tarea 2, conjunto de test).	40
3.6. Ejemplo de predicciones y desempate con F1-score.	48
3.7. F1-score de cada modelo individual frente al sistema de ensemble	48
3.8. Resultados oficiales publicados por la organización del reto MiSonGyny 2025.	51
4.1. Distribución del tiempo invertido en el desarrollo del TFG.	54

Introducción

En nuestra vida, la música tiene un impacto significativo en nuestras emociones. Desde tiempos ancestrales, la humanidad ha utilizado la música como una forma de expresión. Algunos géneros musicales han sido criticados por perpetuar estereotipos de género y promover actitudes sexistas, lo que influye notablemente en la percepción de género entre la población joven. Esta situación contribuye a la aparición de problemáticas como la misoginia.

En este capítulo, se presenta el contexto general del problema abordado y se expone la motivación que impulsa el desarrollo del proyecto. Además, se describen los objetivos planteados, las competencias adquiridas durante el trabajo y la estructura que sigue la presente memoria.

1.1. Motivación

Las letras de canciones forman parte del consumo cultural cotidiano y desempeñan un papel fundamental en la transmisión de valores y actitudes sociales. Investigaciones recientes confirman que la presencia de contenido misógino en las canciones ha aumentado de forma significativa desde los años 60 hasta la actualidad, siendo especialmente notoria a partir del auge de las plataformas digitales y el streaming.

Este tipo de violencia simbólica, aunque a menudo se exprese de forma implícita o estilizada, contribuye a reforzar actitudes discriminatorias y puede normalizar el desprecio, la cosificación o el control sobre las mujeres. Su detección automática representa un desafío técnico relevante, ya que muchas de estas expresiones se comunican mediante metáforas, lenguaje figurado o mensajes sutiles que no siempre contienen palabras explícitamente ofensivas, pero que sí transmiten ideas misóginas.

Ante esta situación, resulta necesario desarrollar soluciones técnicas que permitan abordar el problema desde el ámbito del procesamiento del lenguaje natural. El presente trabajo propone una metodología basada en modelos de lenguaje de gran tamaño (LLMs) y técnicas de aprendizaje profundo, con el objetivo de detectar de forma automatizada patrones misóginos en letras de canciones en español, contribuyendo así a la concienciación social y al desarrollo de herramientas para una moderación más responsable del contenido.

1.2. Objetivos

El objetivo general de este Trabajo de Fin de Grado es desarrollar un sistema de clasificación automática que detecte discursos misóginos en letras de canciones en español, aplicando técnicas de procesamiento del lenguaje natural. El trabajo se apoya en modelos de lenguaje de gran tamaño (LLMs), dentro del marco del aprendizaje automático.

Para alcanzar este objetivo general, se plantean los siguientes objetivos específicos:

- Estudiar distintas técnicas de aprendizaje automático y aprendizaje profundo aplicadas a la clasificación de textos.
- Implementar y ajustar varios modelos de lenguaje, aplicando estrategias como fine-tuning, prompting y técnicas de bajo coste como LoRA.
- Comparar el rendimiento de los modelos mediante métricas de evaluación.
- Analizar los errores de predicción más frecuentes con el fin de identificar posibles mejoras.
- Redactar un artículo científico en el que se recojan la metodología, las decisiones técnicas y los resultados del proyecto.
- Utilizar GitHub para gestionar el desarrollo del proyecto, manteniendo un control de versiones eficaz, una organización clara del código y facilitando la reproducibilidad del trabajo.

Como parte de la validación final del sistema propuesto, se ha participado en la tarea Mi-SonGyny de IberLEF 2025, utilizando el dataset oficial proporcionado por la organización y evaluando el rendimiento del modelo en un entorno competitivo.

1.3. Competencias

Entre las competencias desarrolladas a lo largo de este trabajo destaca:

CE7-C - Capacidad para conocer y desarrollar técnicas de aprendizaje computacional y diseñar e implementar aplicaciones y sistemas que la utilicen.

Junto a esta, el desarrollo del TFG ha permitido también adquirir otras competencias directamente relacionadas con la temática abordada:

- **Capacidad para conocer y desarrollar técnicas de aprendizaje computacional.**

Esta competencia se ha potenciado mediante la investigación, selección y aplicación de diversos métodos de aprendizaje profundo, entre ellos el fine-tuning de modelos de lenguaje de gran tamaño (LLMs) y el diseño de estrategias de prompting adaptadas a la tarea.

- **Capacidad para implementar aplicaciones y sistemas que la utilicen.**

A lo largo del proyecto se ha implementado un sistema funcional capaz de abordar la detección de misoginia en textos, integrando todas las fases del pipeline: desde el preprocesamiento de los datos hasta la evaluación del rendimiento de los modelos. Como resultado, se ha desarrollado también una aplicación que permite cargar nuevas letras, ejecutar el modelo seleccionado y mostrar la predicción correspondiente.

- **Capacidad para la extracción automática de información.**

Esta habilidad se ha ejercitado a través del uso de técnicas de PLN orientadas a identificar automáticamente patrones de contenido misógino en letras de canciones, extrayendo información relevante de forma estructurada a partir de datos no estructurados.

- **Capacidad para adquirir conocimiento a partir de grandes volúmenes de datos.** El manejo de datasets extensos ha requerido el uso de herramientas de análisis y métricas de evaluación que han permitido extraer patrones relevantes y valorar con precisión el rendimiento de los modelos entrenados.

- **Capacidad para gestionar proyectos de desarrollo utilizando plataformas colaborativas en la nube.** Esta competencia se ha desarrollado mediante el uso de GitHub como herramienta para el control de versiones, seguimiento del progreso y organización del código.

- **Capacidad para redactar documentación científica.** Esta competencia se ha desarrollado mediante la elaboración de un artículo científico en formato LaTeX, siguiendo las directrices de una publicación académica oficial, lo que ha requerido estructurar secciones técnicas, aplicar un estilo formal y emplear herramientas de citación.

1.4. Estructura de la memoria

El resto de la memoria se organiza de la siguiente manera:

- En el [Capítulo 2](#), Marco Teórico, se presentan los conceptos clave sobre aprendizaje automático, clasificación de textos y procesamiento del lenguaje natural. También se abordan técnicas como el aprendizaje profundo, el aprendizaje por transferencia y el uso de modelos de lenguaje actuales. Finalmente, se incluyen trabajos relacionados y las herramientas utilizadas en el proyecto.
- En el [Capítulo 3](#), Metodología, Experimentación y Resultados, se expone el enfoque adoptado para dar respuesta a los objetivos del trabajo. Se presenta la competición MiSonGyny 2025, en la que se enmarca este proyecto, y se describen en detalle las distintas fases del pipeline desarrollado: desde la recopilación y preprocesamiento de

datos hasta la configuración y entrenamiento de los modelos. Además, se incluyen las estrategias empleadas para mejorar el rendimiento y se analiza el comportamiento de los modelos a través de un estudio de los errores de predicción más relevantes.

- En el [Capítulo 4](#), Conclusiones y Trabajo Futuro, se recogen las principales conclusiones del proyecto, destacando los resultados obtenidos con los modelos de lenguaje utilizados. También se plantean posibles líneas de mejora y futuras ampliaciones, como la extensión del sistema a otros tipos de discurso de odio o el desarrollo de una aplicación interactiva. Finalmente, se incluye una planificación temporal con las horas estimadas dedicadas a cada fase del trabajo.

La memoria se completa con los siguientes anexos:

- **Anexo A.2:** Desarrollo de una aplicación web para la visualización y prueba del modelo entrenado, implementada con Gradio y desplegada en Hugging Face Spaces.
- **Anexo A.1:** Repositorio público del proyecto en GitHub, que contiene el código, los notebooks y el dataset preprocesado; así como los modelos entrenados, publicados en la plataforma Hugging Face para su consulta y reutilización.
- **Anexo A.3:** Artículo científico presentado en el marco de la competición MiSonGyny 2025, en el que se resume el enfoque seguido y los resultados obtenidos.

Marco Teórico

2.1. Aprendizaje Automático

El aprendizaje automático, o (Machine Learning) [1], es una rama de la inteligencia artificial (IA) que se enfoca en el desarrollo de sistemas capaces de aprender automáticamente a partir de datos, sin ser programados específicamente para esa tarea. El desempeño de estos sistemas puede incrementarse si se proporcionan grandes conjuntos de datos. [2] Este enfoque permite que las máquinas reconozcan patrones complejos, realicen predicciones y tomen decisiones basadas en la información proporcionada.

2.1.1. Tipos de Aprendizaje

El aprendizaje automático se puede clasificar principalmente en tres categorías, según la forma en la que el sistema aprende los datos. [3]

- **Aprendizaje Supervisado** [4]. En el aprendizaje supervisado, los modelos se entrenan utilizando un conjunto de datos etiquetado; cada entrada se acompaña de una salida conocida. El objetivo es que el sistema aprenda a relacionar ambas para predecir resultados en nuevos datos. Se utiliza en tareas como problemas de clasificación y problemas de regresión.
- **Aprendizaje No Supervisado** [5]. Este tipo de aprendizaje se utiliza cuando los datos no están etiquetados. En lugar de predecir salidas, el objetivo es descubrir patrones en los datos. Por ejemplo, *Si el algoritmo recibe imágenes de manzanas y bananas, trabajará por sí solo para categorizar qué imagen es una manzana y cuál es una banana.*[2] Se utiliza en tareas como problemas de clustering, agrupamiento de co-ocurrencias y profiling.
- **Aprendizaje por Refuerzo** [6] En el aprendizaje por refuerzo, el modelo interactúa con un entorno y aprende mediante ensayo y error, recibiendo recompensas o penalizaciones en función de las decisiones tomadas. El objetivo es maximizar la recompensa. Se utiliza en tareas como robótica o videojuegos.




Figura 2.1: Tipos de aprendizaje automático [7]

Como se observa en la [Figura 2.1](#), el aprendizaje automático se divide en tres categorías: Aprendizaje Supervisado, Aprendizaje No Supervisado y Aprendizaje por Refuerzo. Cada una de estas categorías incluye diferentes aplicaciones. Este diagrama muestra una visión general de las principales áreas del campo del machine learning.

En este trabajo se ha utilizado el enfoque de **aprendizaje supervisado**, ya que la tarea principal consiste en la clasificación automática de letras de canciones a partir de un conjunto de datos etiquetado. Esto permite que el modelo aprenda a reconocer patrones en los textos y a predecir la categoría correspondiente en nuevas entradas.

2.2. Clasificación de textos

La clasificación de texto con aprendizaje automático es una técnica fundamental en el campo del procesamiento del lenguaje natural (PLN). Consiste en asignar automáticamente categorías a palabras, frases, párrafos o documentos completos. Esta automatización permite organizar, filtrar y analizar grandes volúmenes de información de forma eficiente. [8]

Este tipo de clasificación se aplica en múltiples contextos, como el análisis de opiniones, la administración de documentos, la atención al cliente, la detección de spam, la moderación de contenido o los sistemas de recomendación.

Existen distintos enfoques de clasificación de texto, dependiendo del número y naturaleza de las categorías:

- **Clasificación binaria** El texto se clasifica en una de dos categorías posibles.
- **Clasificación multiclase** El texto se asigna a una de varias categorías que son mutuamente excluyentes.

- **Clasificación multilabel** El texto puede pertenecer a varias categorías al mismo tiempo.

En ciertos escenarios de clasificación textual, pueden plantearse tareas tanto binarias como multiclase. Algunas tareas complejas también combinan ambas modalidades.

En el contexto de este estudio, la clasificación de textos ha sido aplicada en el contexto de este estudio para detectar automáticamente contenido misógino en letras de canciones. Se ha planteado un primer reto como una **clasificación binaria**, distinguiendo entre letras misóginas y no misóginas, y un segundo reto como **clasificación multiclase**, categorizando las distintas manifestaciones de la misoginia, como el odio, la violencia, la sexualización o la ausencia de estas.

2.3. Aprendizaje profundo

El aprendizaje profundo, o Deep Learning [9], es una rama del aprendizaje automático que emplea redes neuronales con múltiples capas interconectadas para modelar y resolver problemas complejos. Estas redes están inspiradas en la arquitectura del cerebro humano y son capaces de aprender representaciones jerárquicas a partir de grandes volúmenes de datos.

En este trabajo se han aplicado técnicas de aprendizaje profundo para adaptar modelos de lenguaje de gran tamaño a una tarea de clasificación de textos. Para ello, se ajustaron parámetros clave como el número de épocas, el tamaño del lote y la tasa de aprendizaje, combinándolos con estrategias como la detención temprana (early stopping) para mejorar el rendimiento y prevenir el sobreajuste.

2.3.1. Épocas

Una época, o conocidas como epochs, se refiere a una pasada completa por todo el conjunto de datos de entrenamiento durante el proceso de aprendizaje del modelo. Generalmente, se requieren múltiples épocas para que el modelo converja y alcance un rendimiento óptimo. [10]

- **Underfitting** Ocurre cuando el número de épocas es demasiado bajo, el modelo no tiene tiempo suficiente para aprender los datos, suele ocurrir cuando la pérdida de entre entrenamiento y validación sigue siendo alta.
- **Overfitting** Ocurre cuando el número de épocas es demasiado alto, el modelo puede volverse demasiado bueno aprendiendo los ejemplos del entrenamiento y será incapaz de reconocer nuevos datos de entrada.




Figura 2.2: El equilibrio del Aprendizaje [10]

En la [Figura 2.2](#) se observan los tres escenarios comunes en el ajuste de modelos, el primer caso muestra un modelo que no capta la tendencia de los datos, el segundo representa el ajuste adecuado que generaliza bien, y el tercero muestra cómo el modelo se adapta al conjunto de datos de entrenamiento.

2.3.2. Tamaño del lote

El tamaño del lote, también conocido como batch size, se refiere al número de ejemplos de entrenamiento procesados a la vez antes de actualizar los pesos del modelo. [11]

- **Batch size pequeño** Se actualizan los pesos con más frecuencia, lo que puede ayudar a que el modelo se adapte mejor a nuevos datos, sin embargo, el entrenamiento puede ser lento y ruidoso, porque cada lote contiene menos información.
- **Batch size grande** El entrenamiento es más rápido por lote, pero se hacen menos actualizaciones, lo que puede llevar al modelo a soluciones menos óptimas o que no generalizan tan bien.

Batch Size	Advantages	Disadvantages
Small (<32)	Better generalization	Slower training, noisy updates
Medium (32-128)	Balanced training time and accuracy	Often the optimal choice
Large (>128)	Faster computation, smoother updates	Risk of poor generalization

Figura 2.3: Batch Sizes [11]

Como se muestra en la [Figura 2.3](#), se presentan ventajas y desventajas dependiendo del tamaño del lote elegido.

2.3.3. Tasa de aprendizaje

La tasa de aprendizaje es un hiperparámetro fundamental que determina el tamaño de los pasos que da el modelo al ajustar sus pesos en cada iteración del entrenamiento. Tasas de aprendizaje pequeñas harán que se necesiten más épocas de entrenamiento, pero puede producir que el aprendizaje se estanque, mientras que más altas producirán cambios más rápido en cada paso, lo que puede acelerar el entrenamiento, pero también conlleva el riesgo de hacer que el modelo no converja adecuadamente, generando inestabilidad. [12] En el caso de los modelos de lenguaje de gran tamaño (LLMs), es recomendable utilizar una tasa de aprendizaje baja, los LLMs han sido entrenados previamente con grandes corpus de datos. Una tasa baja permite ajustar el modelo a nuevos datos sin sobrescribir el conocimiento adquirido previamente.

2.3.4. Detención temprana

El early stopping es una técnica de regularización que implica detener el entrenamiento del modelo cuando el rendimiento en el conjunto de validación comienza a empeorar. Algunas ventajas de usar esta técnica son prevenir el overfitting o reducir el tiempo de entrenamiento. [13]




Figura 2.4: Early Stopping [14]

Como se observa en la Figura 2.4, el gráfico representa la técnica de early stopping. A medida que aumentan las iteraciones, el error en el conjunto de entrenamiento disminuye, mientras que en el conjunto de validación comienza a aumentar. Con el early stopping, el entrenamiento se detiene en el momento óptimo.

2.4. Modelos de lenguaje actuales

Los Modelos de Lenguaje de Gran Tamaño (LLMs, por sus siglas en inglés) son sistemas avanzados de inteligencia artificial diseñados para comprender y generar lenguaje humano. Están entrenados con enormes cantidades de datos textuales, lo que les permite realizar tareas como traducción, resumen, clasificación, generación de texto y análisis semántico. Estos modelos han revolucionado el campo del procesamiento del lenguaje natural (PLN) y el aprendizaje profundo, permitiendo aplicaciones que van desde asistentes virtuales hasta herramientas de generación de código y análisis de sentimientos.

2.4.1. Características comunes

- **Arquitectura Transformer:** La mayoría de los modelos de lenguaje actuales se basan en una arquitectura llamada Transformer [15]. Esta estructura revolucionó el procesamiento del lenguaje porque permite al modelo analizar el significado de cada palabra teniendo en cuenta su relación con todas las demás en una frase o texto. A diferencia de modelos anteriores, el Transformer puede hacerlo de forma muy rápida y paralela, lo que facilita trabajar con grandes volúmenes de texto sin perder el contexto.
- **Entrenamiento con Grandes Corpus:** Estos modelos se entrenan con grandes volúmenes de datos textuales, obtenidos de fuentes como Wikipedia, libros digitalizados, foros, redes sociales y páginas web. Los corpus suelen ser multilingües y heterogéneos, lo que permite a los modelos adquirir un conocimiento general y robusto del lenguaje y del mundo. La escala del entrenamiento, que puede superar los cientos de miles de millones de palabras.
- **Modelos Autoregresivos:** Una gran parte de los LLMs son autoregresivos, es decir, generan texto de forma secuencial, prediciendo cada palabra o token en función del contexto anterior. Este enfoque ha demostrado ser muy eficaz para la generación coherente de texto.
- **Capacidad Multitarea:** Gracias a un preentrenamiento masivo no supervisado, basado en tareas como la predicción del siguiente token o el relleno de palabras, los LLMs desarrollan representaciones profundas del lenguaje. Esto les permite transferir su conocimiento a múltiples tareas diferentes, con una mínima adaptación posterior. Esta capacidad multitarea los convierte en modelos altamente versátiles para todo tipo de aplicaciones en procesamiento del lenguaje natural.

2.4.2. Modelos Representativos

GPT (OpenAI)

La serie Generative Pre-trained Transformer (GPT) desarrollada por OpenAI ha sido una de las más influyentes en el campo de los modelos de lenguaje de gran tamaño (LLMs). Desde GPT-2, que ya mostraba capacidades generativas notables, la evolución de esta serie ha sido constante. La versión actual, GPT-4 [16], destaca especialmente por su capacidad para realizar tareas de razonamiento complejo, comprender contextos amplios y generar texto de forma coherente y precisa. Este modelo se emplea ampliamente en aplicaciones como asistentes conversacionales, generación de código y tareas creativas en diversos dominios.

LLaMA (Meta)

LLaMA (Large Language Model Meta AI) es una familia de modelos de lenguaje desarrollada por Meta AI, diseñada para ser eficiente, abierta y accesible. A diferencia de otros modelos de gran escala, LLaMA ha sido entrenado exclusivamente con datos públicos, lo que facilita su uso y estudio en el ámbito académico. Su tercera generación, LLaMA 3, ofrece un rendimiento competitivo en tareas avanzadas de procesamiento del lenguaje natural (PLN) y está disponible para la comunidad investigadora [17].

Qwen (Alibaba Group)

Qwen3 [18] es una familia de modelos de lenguaje de código abierto desarrollada por Alibaba, diseñada para ofrecer un rendimiento competitivo en tareas complejas mediante un enfoque de razonamiento híbrido. Esta nueva generación incluye tanto modelos densos como de mezcla de expertos, con soporte para hasta 128K tokens de contexto. Entrenados en una amplia variedad de idiomas, Qwen3 destaca por su capacidad multilingüe, eficiencia computacional y flexibilidad, lo que facilita su integración en distintos entornos de desarrollo.

DeepSeek (DeepSeek AI)

DeepSeek es una familia de modelos de lenguaje de código abierto desarrollada por la empresa china DeepSeek AI. Su versión más destacada, DeepSeek-R1 [19], ha sido entrenada mediante aprendizaje por refuerzo con el objetivo de potenciar sus capacidades de razonamiento. Gracias a este enfoque, ha alcanzado un rendimiento comparable al de modelos propietarios como OpenAI-o1. Destaca especialmente en tareas complejas como

matemáticas, codificación y resolución de preguntas tipo examen, posicionándose como una alternativa potente, eficiente y accesible dentro del ecosistema de LLMs.

2.5. Procesamiento del Lenguaje Natural

El procesamiento del lenguaje natural (PLN) [20] es una rama de la inteligencia artificial que se enfoca en la interacción con el lenguaje humano. Su objetivo es permitir que las máquinas comprendan, interpreten y generen texto de manera que resulte natural. Se aplica en ámbitos tan diversos como la sanidad, las finanzas, la atención al cliente y el comercio electrónico, así como en aplicaciones cotidianas como los asistentes virtuales o los motores de búsqueda.

En el contexto de la detección de misoginia en letras de canciones, el PLN es fundamental, ya que permite automatizar el análisis, identificando patrones que puedan reflejar actitudes sexistas o discriminatorias contra la mujer. [21]

2.5.1. Preprocesamiento del texto

El preprocesamiento es una etapa clave del procesamiento del lenguaje natural, consiste en preparar los datos textuales para que puedan ser interpretados por los modelos de aprendizaje. Los datos lingüísticos, como en este caso las letras de canciones, suelen tener ruido, por lo que es necesario ajustar antes de su análisis. Entre las tareas de preprocesamiento más comunes se encuentran: [22]

- **Tokenización** Proceso de dividir el texto en unidades más pequeñas, llamadas tokens.
- **Lematización** Es la reducción de las palabras a su forma base.
- **Eliminación de stopwords** Se eliminan palabras muy frecuentes y poco informativas ya que no aportan ningún valor semántico relevante 'de', 'la', 'y', 'el'.
- **Normalización** Convertir todo el texto a minúsculas, eliminar signos de puntuación, caracteres especiales o espacios en blanco innecesarios.

Como se observa en la [Tabla 2.1](#), se muestran los distintos tipos de preprocesamiento explicados que se pueden aplicar en el contexto de una canción, desde la normalización hasta la lematización, permitiendo preparar el texto para su posterior análisis.

similares.

2.5.3. Tipos de prompting en LLMs

Modelos como GPT, Llama, Gemma o Deepseek, han demostrado una gran capacidad de realizar tareas de procesamiento del lenguaje natural sin necesidad de un entrenamiento específico, gracias a su entrenamiento previo. [24]

- **Zero-shot** Utiliza únicamente el conocimiento adquirido durante la fase de preentrenamiento. En este enfoque se proporciona al modelo una instrucción clara sin ejemplos.

Analiza la siguiente letra de canción y determina si contiene contenido misógino.

La misoginia incluye expresiones de odio, desprecio, cosificación o violencia hacia las mujeres.

Responde 'Sí' si la letra contiene misoginia, o 'No' si no la contiene.

Letra: 'Ella es solo un juguete por esta noche, no significa nada para mí, no me importa lo que diga, es mía hasta que yo termine.'

- **Few-shot** Este enfoque implica proporcionar al modelo un número de ejemplos de entrada con su correspondiente salida. Estos servirán como guía para que el modelo comprenda el patrón deseado.

Analiza cada letra de canción y determina si contiene contenido misógino. La misoginia incluye expresiones de odio, desprecio, cosificación o violencia hacia las mujeres.

Responde 'Sí' si contiene misoginia y explica por qué, o 'No' si no la contiene.

Ejemplo 1:

Letra: 'Esa zorra no merece nada, solo está para calentar la cama.'

Respuesta: Sí.

Ejemplo 2:

Letra: 'Cuando la miro, el mundo se detiene, y solo quiero cuidarla y verla feliz.'

Respuesta: No.

- **Chain of Thought** Esta técnica de instrucción mejora la capacidad de razonamiento de los LLMs al incluir pasos dentro del prompt. Esto permite que el modelo divida una tarea compleja en etapas más simples, lo que da lugar a resultados más precisos.

Analiza la siguiente letra de canción paso a paso para determinar si contiene contenido misógino.

La misoginia puede manifestarse a través de insultos, desprecio, cosificación sexual, violencia o dominio hacia las mujeres.

Primero, identifica los elementos clave del lenguaje usados en la letra.

Después, razona si alguno de esos elementos representa una forma de misoginia.

Finalmente, responde 'Sí' si hay misoginia y explica por qué, o 'No' si no la hay.

Letra:

'Ella es solo un juguete por esta noche, no significa nada para mí, no me importa lo que diga, es mía hasta que yo termine.'

Paso 1 – Identificación del lenguaje:

La letra utiliza expresiones como 'solo un juguete', 'no significa nada', 'no me importa lo que diga' y 'es mía hasta que yo termine'.

Paso 2 – Análisis del contenido:

'Solo un juguete' implica una cosificación: reduce a la mujer a un objeto sin valor propio. 'No significa nada para mí' denota desprecio y deshumanización. 'No me importa lo que diga' niega la voluntad o voz de la mujer. 'Es mía hasta que yo termine' implica posesión y control, lo cual refuerza un discurso de dominación masculina.

Paso 3 – Conclusión:

Sí. Esta letra contiene múltiples elementos que expresan misoginia, incluyendo cosificación, deshumanización y dominación de la mujer.

2.6. Aprendizaje por Transferencia

El aprendizaje por transferencia [25] es una técnica que consiste en reutilizar el conocimiento previamente adquirido por un modelo en una tarea, con el fin de mejorar el rendimiento en otra tarea relacionada. En lugar de entrenar el modelo desde cero se parte de un modelo previamente entrenado y se adapta a la nueva tarea con menos datos y tiempo. Esta práctica está relacionada a cómo los humanos actuamos, ya que nuestra experiencia nos ayuda a afrontar los problemas del día a día.

En el ámbito del Procesamiento del Lenguaje Natural, el aprendizaje por transferencia ha supuesto un avance significativo. Gracias al uso de modelos entrenados previamente sobre grandes cantidades de texto, es posible aplicar fine-tuning para ajustarlos a tareas concretas, optimizando así su rendimiento y reduciendo la necesidad de recursos computacionales y datos etiquetados. [26]

En este trabajo, se ha aplicado aprendizaje por transferencia para adaptar modelos de lenguaje preentrenados sin sobrescribir el conocimiento previamente adquirido, lo que ha permitido preservar la comprensión contextual necesaria para interpretar adecuadamente el significado completo de las letras de canciones.

2.6.1. Fine-tuning y optimización de hiperparámetros.

El fine-tuning es una técnica esencial dentro del aprendizaje por transferencia, consiste en ajustar los pesos del modelo preentrenado para adaptarlo a la nueva tarea. Este proceso permite aprovechar el conocimiento adquirido previamente. [21]

Los hiperparámetros son configuraciones externas al modelo, que influyen en su proceso de aprendizaje, el tamaño del lote (batch size), el número de épocas, tasa de aprendizaje, etc. La optimización de estos hiperparámetros es esencial para maximizar el rendimiento del modelo y evitar problemas de sobreajuste (overfitting) o subajuste (underfitting).

2.6.2. LoRA

LoRA (Low-Rank Adaptation) [27] es una técnica que permite adaptar modelos de lenguaje de gran tamaño a tareas más específicas sin necesidad de ajustar todos sus parámetros.

En lugar de modificar todos los parámetros del modelo preentrenado, LoRA introduce pequeñas matrices entrenables en cada capa del modelo y mantiene congelados los pesos originales. Esto reduce de forma considerable la cantidad de parámetros que deben actualizarse durante el entrenamiento, lo que hace que el proceso sea más eficiente tanto en tiempo como en consumo de memoria. Una de las principales ventajas de LoRA es que permite realizar fine-tuning sin necesidad de almacenar ni redistribuir el modelo completo ajustado: basta con guardar las matrices añadidas, lo que facilita la reutilización.

Además, LoRA ha ganado gran popularidad en el ajuste de modelos de lenguaje de gran tamaño (LLMs), ya que permite entrenarlos eficazmente incluso en entornos con recursos limitados, como GPU de gama media o sesiones en Google Colab.

- **Ventajas** Al entrenar sólo una parte de los parámetros, LoRA reduce significativamente el tiempo de entrenamiento y el uso de memoria, además, al mantener congelados los pesos originales del modelo se ayuda a conservar el rendimiento en tareas no relacionadas y evitando el problema del olvido catastrófico.
- **Desventajas** La principal desventaja de LoRA es que puede no ser tan efectiva en tareas que requieren un ajuste más profundo del modelo, ya que solo se ajustan las matrices añadidas.

2.7. Ensemble de modelos

El ensemble de modelos es una técnica que consiste en combinar las predicciones de varios modelos individuales con el objetivo de mejorar el rendimiento general del sistema. La idea principal es que, al integrar modelos con distintos puntos fuertes y débiles, el conjunto

pueda compensar los errores individuales y alcanzar una precisión superior a la que lograría cualquier modelo por separado. [28]

Esta estrategia parte del supuesto de que los modelos base cometen errores diferentes, por lo que al agregarlos se reduce la probabilidad de fallo conjunto. En la práctica, el ensemble suele mejorar la capacidad de generalización y la robustez del sistema.

En el desarrollo de este trabajo, se implementará un enfoque de ensemble utilizando cuatro modelos. Para determinar la predicción final, se aplicará la estrategia de votación mayoritaria, que consiste en que la clase que obtuvo el mayor número de votos es la seleccionada como la predicción del conjunto. En los casos en los que se produce empate, se optará por desempatar usando un criterio basado en la métrica F1-score.

La Figura 2.6 ilustra de forma esquemática el funcionamiento del sistema de ensemble implementado. A partir de los mismos datos de test, se generan predicciones independientes mediante cuatro modelos diferentes. Posteriormente, estas predicciones son combinadas a través de una estrategia de votación mayoritaria. En el ejemplo mostrado, tres de los modelos predicen la clase 1 (misógina), mientras que uno predice la clase 0. Como resultado, el ensemble selecciona la clase 1 como predicción final.




Figura 2.6: Esquema de funcionamiento del ensemble por votación mayoritaria.

2.8. Medidas de Evaluación

En el ámbito del aprendizaje automático, la evaluación de modelos de clasificación se realiza mediante diversas métricas que permiten determinar su rendimiento. Existen diversas

medidas para evaluar modelos de clasificación en tareas similares a la detección de misoginia, se emplean las siguientes métricas tanto para la tarea de clasificación binaria como multiclase.[29]

En el desarrollo de este trabajo se han utilizado las métricas de precisión, recall, F1-score y macro-average como criterios principales para evaluar el rendimiento de los modelos tanto en la tarea de clasificación binaria como en la multiclase.

- **Precision:** La precisión mide la proporción de verdaderos positivos entre todas las predicciones realizadas. Indica cuántas de las predicciones positivas realizadas por el modelo fueron correctas.

$$\text{Precision} = \frac{TP}{TP + FP}$$

- **Recall:** El recall, o sensibilidad mide la proporción de verdaderos positivos detectados por el modelo respecto del total de casos positivos reales. Esta métrica resulta clave cuando lo más importante es identificar todos los casos positivos.

$$\text{Recall} = \frac{TP}{TP + FN}$$

- **F1-score:** Esta medida combina precisión y recall en una única métrica, utilizando la media armónica. Es útil cuando se desea un equilibrio entre ambas métricas, como en casos de clases desbalanceadas. Suele ser la métrica más elegida en tareas de clasificación.

$$\text{F1-score} = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

- **Macro-Average:** Consiste en calcular precisión, recall y F1-score de forma independiente para cada clase y luego obtener la media. Esto asegura que cada clase tenga el mismo peso. Es especialmente útil en tareas multiclase.

$$B_{\text{macro}} = \frac{1}{q} \sum_{\lambda=1}^q B(tp_{\lambda}, fp_{\lambda}, tn_{\lambda}, fn_{\lambda})$$

Además de estas métricas, para visualizar el rendimiento del modelo de forma más intuitiva, se ha generado la **matriz de confusión**. Esto permite observar la distribución de aciertos y errores de cada clase.

		El modelo predice...	
		POSITIVO	NEGATIVO
La realidad es...	POSITIVO	VERDADERO POSITIVO (TP)	FALSO NEGATIVO (FN)
	NEGATIVO	FALSO POSITIVO (FP)	VERDADERO NEGATIVO (TN)

Figura 2.7: Matriz de confusión [30]

Como se presenta en la [Figura 2.7](#), la matriz de confusión es una herramienta fundamental para visualizar y evaluar el rendimiento de un modelo de clasificación. En ella se comparan las etiquetas predichas por el modelo con las etiquetas reales del conjunto de datos. La matriz se divide en cuatro o más cuadrantes:

- **Verdadero Positivo (TP):** El modelo predice la clase positiva y acierta. Representa los casos en los que el sistema identifica correctamente una instancia positiva.
- **Falso Positivo (FP):** El modelo predice clase positiva, pero en realidad era negativa. Implica que se ha clasificado erróneamente como positiva una instancia que no lo era.
- **Falso Negativo (FN):** El modelo predice clase negativa cuando en realidad era positiva. En este caso, no se detecta una instancia positiva, lo cual puede ser especialmente problemático en contextos sensibles como la detección de discurso de odio.
- **Verdadero Negativo (TN):** El modelo predice clase negativa y acierta. Corresponde a los casos correctamente identificados como negativos.

Gracias a esta representación, es posible calcular métricas esenciales como la precisión (precision), la exhaustividad (recall) y el F1-score, además de ofrecer una visión más clara del tipo de errores que comete el modelo.

2.9. Trabajos relacionados

Diversos estudios recientes han puesto de manifiesto cómo las letras de canciones pueden reproducir estereotipos de género y actitudes sexistas, lo que resulta especialmente relevante

dado el impacto social de la música. En este contexto, el análisis automático de letras de canciones mediante técnicas de procesamiento del lenguaje natural (PLN) se ha convertido en una línea de investigación en auge, con el objetivo de detectar sesgos de género y evaluar su evolución a lo largo del tiempo.

Un ejemplo destacado es el trabajo de Casanovas-Buliart et al. (2024) [31], que llevó a cabo un análisis de 2.840 letras de las canciones más escuchadas en España entre 1960 y 2022. Mediante el uso de aprendizaje automático supervisado, entrenaron modelos con un conjunto de párrafos etiquetados manualmente como sexistas o no sexistas, considerando distintas categorías como estereotipos de rol, hipersexualización, control, violencia simbólica o cosificación hacia la mujer. El estudio reveló que el 51 % de las canciones contenían algún tipo de contenido sexista, con un aumento especialmente significativo desde 2015, coincidiendo con el auge de las plataformas de streaming. Además, se observó que los casos de sexismo eran más frecuentes en canciones en español y que las expresiones sexistas solían incluir referencias explícitas al cuerpo femenino y justificaciones del dominio masculino en el marco del amor romántico. Estos resultados muestran cómo la música popular sigue reproduciendo narrativas de desigualdad de género.

Chen et al. (2025) [32] analizaron más de 537.000 letras de canciones en inglés mediante técnicas de modelado de temas (BERTopic) y evaluación de sesgo semántico (SC-WEAT). Su estudio abarcó cinco géneros musicales principales y reveló una evolución temática desde letras románticas hacia una creciente sexualización de la mujer, especialmente en el rap. El tema más recurrente, identificado por el modelo, incluía un uso elevado de lenguaje misógino y explícito.

A nivel semántico, se observó una asociación sistemática entre atributos como inteligencia, fuerza o violencia con lo masculino, mientras que términos relacionados con apariencia física y debilidad mostraron un sesgo femenino. Estos patrones, presentes en todos los géneros analizados, evidencian un desequilibrio de género persistente en la música.

Por otro lado, Calderón-Suárez et al. (2023) [33] propusieron una estrategia de aumento de datos basada en la incorporación de fragmentos misóginos extraídos de letras de canciones, con el objetivo de mejorar el rendimiento de los sistemas de detección de misoginia en redes sociales. Su hipótesis se basaba en la idea de que las letras musicales contienen un lenguaje rico y variado que expresa actitudes misóginas de formas muy diversas, lo que las convierte en una fuente útil para enriquecer el entrenamiento de modelos. Los resultados obtenidos confirmaron que esta estrategia contribuye a generar modelos más robustos, especialmente en entornos con escasez de datos anotados, lo que resalta el valor de la música como recurso en tareas de detección automática de discurso de odio.

También se han desarrollado trabajos centrados en la detección automática de misoginia y sexismo en contenido generado por usuarios en redes sociales. AMI (2020) [34] abordó la identificación de mensajes misóginos y agresivos en publicaciones en italiano, proponiendo dos tareas: detección de misoginia y agresividad, y evaluación de la equidad

de los modelos ante posibles sesgos. Por su parte, EXIST (2022) [35] propuso un conjunto de datos multilingüe en inglés y español, orientado tanto a la clasificación binaria de contenido sexista como a su categorización en diferentes tipos de sexismo. Uno de los principales aportes de este trabajo fue subrayar la dificultad de detectar formas sutiles de sexismo, como aquellas expresadas mediante ironía, ambigüedad o lenguaje indirecto.

Siguiendo esta línea de trabajo, HOMO-MEX (2024) [36] incluyó una subtask centrada específicamente en la detección de contenido LGBT+fóbico en letras de canciones en español. Para ello, se elaboró un conjunto de datos compuesto por más de 1.200 letras anotadas, recopiladas mediante métodos automáticos y complementadas con una selección manual realizada con el criterio de personas pertenecientes a la comunidad LGBT+. Este trabajo pone de relieve la complejidad de detectar discurso de odio cuando se expresa mediante lenguaje figurado o poético, ya que estos recursos estilísticos suelen ocultar el contenido dañino tras metáforas o expresiones difíciles de interpretar de forma literal.

2.10. Tecnologías y recursos utilizados



Python: Lenguaje de programación del proyecto, ampliamente utilizado en inteligencia artificial y aprendizaje automático por su sencilla sintaxis y su amplia gama de bibliotecas que facilitan el desarrollo.



Pytorch: Es un framework de Deep Learning, permite construir y entrenar redes neuronales de forma intuitiva.



Jupyter Notebook: Herramienta interactiva que permite la ejecución de código por bloques, visualizar los resultados y añadir texto en un solo documento.



Google Colab: Plataforma en la nube que permite ejecutar cuadernos de Jupyter de forma gratuita con acceso a recursos como GPUs.



Unsloth: Biblioteca optimizada para acelerar y facilitar el fine-tuning de modelos LLM.



Hugging Face: Plataforma para utilizar y personalizar modelos pre-entrenados como Deepseek R1, Llama 3 o Gemma 3.



Weights & Biases (W&B): Herramienta para seguimiento de pruebas, permite monitorizar métricas, visualizar resultados, comparar ejecuciones.



GPU del laboratorio I2C: Buena parte del entrenamiento se ha llevado a cabo en entornos locales del grupo de investigación para optimizar la velocidad del proceso.



MySonGyny: Competición dentro de IberLEF 2025 que ha proporcionado el dataset utilizado como base para el desarrollo del proyecto.

Metodología, Experimentación y Resultados

En este capítulo se describe el enfoque metodológico seguido para abordar la detección de misoginia en letras de canciones, así como las fases de experimentación llevadas a cabo y los resultados obtenidos. Primero, se presenta el contexto del reto en el que se enmarca el trabajo, seguido de una visión general de la metodología empleada. A continuación, se detallan los pasos realizados en la preparación de los datos, la selección y entrenamiento de los modelos, el ajuste de hiperparámetros y las estrategias de evaluación. Finalmente, se analizan los resultados obtenidos y se discuten los aciertos y errores del sistema propuesto.

3.1. Participación en un reto

Este trabajo se ha desarrollado en el marco del reto **MiSonGyny 2025**, organizado en el contexto del workshop **IberLEF (Iberian Languages Evaluation Forum)**, celebrado dentro de la conferencia **SEPLN 2025**. El objetivo principal de este reto es fomentar el desarrollo de sistemas automáticos capaces de detectar y clasificar contenido misógino en letras de canciones en lengua española.

Este tipo de tarea es de gran relevancia en el ámbito del Procesamiento del Lenguaje Natural (PLN), permiten avanzar en la creación de herramientas que contribuyan a identificar discursos dañinos o discriminatorios.

La edición de 2025 planteó dos sub-tareas diferenciadas:

- **Tarea 1: Clasificación binaria.** Determinar si una letra contiene o no contenido misógino. Las etiquetas disponibles eran **M** (misógino) y **NM** (no misógino).
- **Tarea 2: Clasificación multiclase.** Clasificar el tipo de misoginia presente, en caso de existir, dentro de una de las siguientes categorías: **V** (violencia), **H** (odio), **S** (sexualización) o **NR** (no relacionada).

Los datos proporcionados consistían en letras de canciones en español, extraídas mediante scraping de AZLyrics y validadas con la API de Genius. Todas las instancias fueron entregadas ya anotadas, y el conjunto ofrecido era exclusivamente de entrenamiento, por lo que cada participante debía generar sus propios conjuntos de validación y test.

La evaluación de los sistemas se realizó utilizando las métricas estándar en tareas de clasificación: precisión (precision), exhaustividad (recall) y F1-score, siendo esta última la métrica principal para determinar el ranking.

En esta edición participaron un total de **39 equipos**. El sistema desarrollado en este trabajo obtuvo el **segundo mejor resultado** para ambas tareas, posicionándose por encima de la media general y destacando por su capacidad de generalización y estabilidad en la clasificación.

3.2. Descripción de la metodología

El marco de experimentación se ha dividido en varias fases: preprocesamiento de los datos, diseño y entrenamiento de los modelos, y evaluación de su rendimiento. En esta sección se ofrece una visión general del proceso completo, que será detallado en los apartados posteriores.

A lo largo del desarrollo del trabajo se ha seguido un enfoque supervisado basado en el uso de modelos de lenguaje de gran tamaño (LLMs), adaptados mediante técnicas de fine-tuning. La metodología se ha centrado en diseñar y entrenar dos sistemas, orientados a cada una de las tareas planteadas (clasificación binaria y clasificación multiclase).

Las principales etapas del proceso han sido las siguientes:

1. **Análisis de los datos:** Estudio inicial del dataset, frecuencia de clases, características del texto y detección de desbalanceo.
2. **Preprocesamiento de los datos:** Limpieza y normalización de los textos, remapeo de etiquetas, técnicas de balanceo, preparación y formateo de las entradas para los modelos.
3. **Selección de modelos:** Elección de modelos adecuados para cada tarea, incluyendo modelos de lenguaje de gran tamaño (LLMs) multilingües y un modelo Transformer como baseline.
4. **Ajuste de hiperparámetros:** Exploración manual de valores para parámetros clave como learning rate, número de épocas, batch size y configuración de LoRA.
5. **Entrenamiento de los modelos:** Aplicación de diferentes estrategias de fine-tuning, incluyendo el uso de prompts y cadenas de razonamiento para mejorar la alineación con la tarea.
6. **Análisis de resultados:** Evaluación de los modelos utilizando métricas como precision, recall y F1-score, así como análisis de errores y comparación entre modelos.

La [Figura 3.1](#) muestra el esquema general del pipeline seguido en este trabajo, desde la preparación de los datos hasta la generación de predicciones finales mediante un enfoque

ensemble.




Figura 3.1: Esquema general del pipeline seguido en este trabajo. Se representa el flujo completo desde la preparación de los datos y la generación de cadenas de razonamiento, hasta el entrenamiento, evaluación y combinación de modelos mediante ensemble.

El proceso comienza con el conjunto de datos proporcionado por la organización del reto MiSonGyny 2025. Este dataset se divide en datos de entrenamiento y prueba. Los datos de entrenamiento son preprocesados para eliminar ruido, normalizar texto, remapear etiquetas y aplicar técnicas de balanceo, como el oversampling, con el fin de mejorar la calidad de los datos que se utilizarán para entrenar los modelos.

En paralelo, se explora el uso de cadenas de razonamiento (Chain of Thought) para enriquecer los ejemplos de entrenamiento. Estas cadenas son generadas automáticamente por modelos LLM (como GPT-4o o Salamandra) y añadidas a los prompts, con el objetivo de guiar al modelo a través de un razonamiento más explícito.

Una vez preparados los datos, se procede al entrenamiento de modelos de lenguaje de gran tamaño, como Qwen3, LLaMA 3.1 y DeepSeek R1. Durante esta fase, se realiza ajuste manual de hiperparámetros (learning rate, batch size, número de épocas, parámetros de LoRA), guiado por la observación directa de las métricas en el conjunto de validación.

Tras entrenar los modelos, se evalúan sus resultados con el conjunto de test. Esta evaluación incluye el cálculo de métricas. Además, se analizan los errores y se ajustan las configuraciones según sea necesario.

Finalmente, se aplicó una técnica de ensemble sobre los modelos entrenados. La predicción final para cada ejemplo se obtuvo mediante votación mayoritaria entre los modelos, y en caso de empate se aplicó como criterio de desempate la métrica F1-score. Este enfoque permitió combinar las fortalezas individuales de cada modelo, obteniendo una salida más

robusta y precisa.

3.3. Análisis de los datos

Antes de entrenar cualquier modelo, se realizó un análisis exploratorio del conjunto de datos proporcionado por la organización del reto **MiSonGyny 2025**. El objetivo de esta fase era comprender la estructura de los datos, la distribución de clases y detectar posibles desequilibrios que pudieran afectar al rendimiento del modelo.

El dataset estaba formado por letras de canciones en español, con algunos fragmentos ocasionales en inglés. Los textos presentaban una gran variabilidad tanto en estilo como en longitud. El número medio de caracteres por canción era de **1531.30**, con un mínimo de **45** caracteres y un máximo de **11720**, lo que indica la necesidad de que los modelos puedan manejar contextos extensos.

La [Figura 3.2](#) muestra cómo se distribuyen las longitudes de las letras del dataset. La mayoría de las canciones tienen menos de 2500 caracteres, aunque también hay algunas más extensas. Esta variación en la longitud confirma que los modelos deben estar preparados para manejar textos de tamaño diverso. Las líneas verticales marcan los valores mínimo, medio y máximo, lo que ayuda a hacerse una idea del rango de los datos.




Figura 3.2: Distribución de la longitud de letras de canciones en el conjunto de datos.

La [Figura 3.3](#) muestra las palabras más representativas en las letras clasificadas como misóginas, evidenciando un uso recurrente de términos como 'baby', 'mami' o 'cama', que reflejan una tendencia hacia la cosificación y el lenguaje sugestivo.




Figura 3.3: Top 20 palabras con mayor diferencia de frecuencia en letras etiquetadas como misóginas.

Por contraste, la [Figura 3.4](#) muestra las palabras más representativas en letras no misóginas, donde se aprecia un léxico centrado en el amor, la emoción y el ámbito personal, destacando palabras como 'alma', 'amor' o 'vida'.




Figura 3.4: Top 20 palabras con mayor diferencia de frecuencia en letras clasificadas como no misóginas.

En cuanto a la distribución de clases:

- Para la **Tarea 1 (Clasificación binaria)**, el dataset contenía un total de **2104** letras, de las cuales **642** eran misóginas (M) y **1462** no misóginas (NM). Esto indica un cierto desbalance, con aproximadamente el 69 % de las instancias clasificadas como no misóginas.

La [Figura 3.5](#) muestra esta distribución de clases de forma visual, lo cual permite apreciar más claramente el desequilibrio presente en el conjunto de datos.




Figura 3.5: Distribución de clases en el conjunto de datos de la Tarea 1.

- Para la **Tarea 2 (Clasificación multiclase)**, el conjunto de datos se dividía en:
 - **Violencia:** 129 instancias
 - **Odio:** 78 instancias
 - **Sexualización:** 435 instancias
 - **No Relacionada:** 526 instancias

En este caso, también se observa un desbalance significativo en las clases de odio y violencia.

A continuación, se muestra un gráfico [Figura 3.6](#) que representa visualmente esta distribución de clases en forma porcentual, con el objetivo de facilitar la identificación del desequilibrio entre categorías.

Este análisis permitió identificar desafíos importantes relacionados con la longitud de los textos, el lenguaje informal y el desbalance entre clases, elementos clave a tener en cuenta durante la fase de preprocesamiento y entrenamiento.

3.4. Preprocesamiento de los datos

Una vez analizado el corpus, se procedió al preprocesamiento de los datos con el objetivo de adaptar las letras de canciones a un formato compatible con los modelos de lenguaje.




Figura 3.6: Distribución de clases en el conjunto de datos de la Tarea 2.

- **Normalización y limpieza del texto:** Todos los textos se convirtieron a minúsculas y se eliminaron caracteres no alfabéticos, signos de puntuación innecesarios, símbolos especiales, nombres de artistas y otros elementos que no aportaban valor semántico a la tarea. La [Tabla 3.1](#) muestra un ejemplo representativo de una letra antes y después de aplicar este proceso de limpieza.
- **Remapeo de etiquetas:** En ambas tareas, las etiquetas originales fueron transformadas en valores numéricos para facilitar el entrenamiento. En la Tarea 1, NM y M se codificaron como 0 y 1 respectivamente. En la Tarea 2, las etiquetas NR, S, V y H se codificaron como 0, 1, 2 y 3.
- **Balanceo de clases:** En ambas tareas se aplicó una estrategia de oversampling sobre el conjunto de entrenamiento para equilibrar la proporción entre clases. Las instancias correspondientes a las clases minoritarias fueron replicadas hasta alcanzar una distribución más equitativa logrando un aumento aproximado del 44 %. Esta técnica ayudó a mejorar la capacidad del modelo para detectar ejemplos menos representados.

Además, como parte de la preparación de los datos, se añadió un prompt personalizado a cada letra de canción. Este prompt incluía una instrucción clara que explicaba la tarea que el modelo debía realizar, seguida del texto de la canción y, finalmente, la salida esperada (la clase correspondiente). De esta forma, se generaban ejemplos completos de entrada-salida que permitían aplicar un enfoque de prompt-based fine-tuning.

Tabla 3.1: Ejemplo de letra original y resultado tras aplicar normalización y limpieza de texto.

Original	Preprocesado
[Intro-Scratch] Flor de vida, flor de vida... Los paisajes cambian Un chico de carácter agradable [?] de suicidio, puede grabarlo en vídeo ...	flor de vida flor de vida los paisajes cambian un chico de carácter agradable de suicidio puede grabarlo en vídeo

3.4.1. Cadenas de pensamiento (Chain of Thought)

Con el objetivo de enriquecer aún más la entrada proporcionada al modelo, se exploró una variante del prompt tradicional basada en la generación de cadenas de pensamiento (Chain of Thought). Este enfoque consistía en añadir, entre la letra de la canción y la etiqueta final, una explicación intermedia que razonara paso a paso sobre el contenido, destacando aquellos elementos relevantes. Para generar estas cadenas de razonamiento se utilizaron dos métodos automáticos: por un lado, llamadas a la API de GPT-4o, y por otro, el modelo local Salamandra 7B. Ambos métodos generaron explicaciones que se insertaron en el prompt, con el objetivo de guiar al modelo hacia una mejor comprensión del contexto y la tarea.

Este procedimiento fue aplicado exclusivamente en los experimentos realizados con el modelo DeepSeek R1, con el objetivo de evaluar si la presencia de razonamiento explícito podía mejorar su rendimiento.

Ejemplo: A continuación se presenta un ejemplo de la generación de un Chain of Thought para una letra de canción por GPT-4o:

1. *La letra se centra en la expresión de dolor y tristeza por la ausencia de una persona amada, sin hacer referencia a la degradación o deshumanización de mujeres.*
2. *No hay indicios de menosprecio explícito o implícito hacia las mujeres; el enfoque está en el sufrimiento emocional del hablante.*
3. *La canción no refuerza estereotipos negativos o dañinos hacia las mujeres, ya que se trata de una experiencia personal de pérdida y añoranza.*
4. *No se promueve ni se menciona la violencia hacia las mujeres en ninguna parte de la letra.*

3.5. Selección de modelos

A la hora de abordar las tareas de clasificación propuestas, se consideró que los modelos de lenguaje de gran tamaño (LLMs) ofrecían una solución adecuada, gracias a su capacidad para captar matices semánticos complejos y adaptarse a tareas específicas. Dado que las letras de canciones presentan un lenguaje informal, variado y a menudo ambiguo, los LLMs se ajustaban bien a las necesidades del problema.

Durante las primeras fases del proyecto se exploró el uso de Longformers [37], más concretamente **longformer-base-4096-bne-es**, un modelo Transformer, diseñado para trabajar con secuencias largas. Este modelo resultaba especialmente interesante por su capacidad para gestionar entradas extensas, como muchas de las canciones del dataset. Sin embargo, aunque su rendimiento era aceptable como punto de partida, su capacidad de adaptación era limitada en comparación con la de los modelos más recientes. Por este motivo, el Longformer se mantuvo como punto de partida para establecer una referencia, pero fue descartado como candidato final.

Durante la experimentación, se optó por utilizar versiones optimizadas de estos modelos a través de la biblioteca Unsloth, que permite acelerar el fine-tuning mediante una implementación eficiente y un uso reducido de memoria. Estas versiones ya venían cuantizadas en 4 bits. Los modelos utilizados fueron:

- **Qwen3-8B:** Desarrollado por Alibaba, fue elegido por su robustez en tareas multiclase, su alta capacidad de generalización y su buen rendimiento en español, a pesar de no estar específicamente entrenado para ello. Destacó especialmente por su equilibrio entre precisión y estabilidad.
- **Meta-LLaMA-3.1-8B:** Gran popularidad en la comunidad, fue seleccionado por su arquitectura moderna, su rendimiento competitivo y su buena adaptación a tareas de clasificación mediante instrucciones claras.
- **DeepSeek-R1-Distill-Llama-8B:** Fue incorporado por su buen desempeño en tareas con razonamiento paso a paso, como las cadenas de pensamiento (Chain of Thought), lo que permitía experimentar con técnicas avanzadas de prompting para mejorar la interpretabilidad del modelo.

3.6. Ajuste de hiperparámetros

El ajuste se realizó mediante un enfoque manual, apoyando en la monitorización con **Weights & Biases (WandB)** [38]. No se aplicaron técnicas sistemáticas como búsqueda aleatoria o grid search, sino que se probaron una a una, guiadas por la observación directa de las curvas de validación y el rendimiento de los modelos.

3.6.1. Hiperparámetros Evaluados

Durante esta fase se exploraron distintos valores:

- **Tasa de aprendizaje (learning rate):** Se probaron valores entre $1e-5$ y $5e-5$, siendo $2e-5$ el más efectivo.
- **Batch size:** debido a las limitaciones de memoria, se utilizó una configuración con acumulación por gradientes que permitía mantener un *batch efectivo de 64*. Esta estrategia permitió aprovechar la capacidad de la GPU sin comprometer la estabilidad del entrenamiento.
- **Número de épocas:** Se realizaron pruebas con 3, 5 y 10 épocas, utilizando detección temprana (early stopping), para evitar el sobreajuste.
- **LoRA rank:** Se probaron valores de LoRA rank y alpha entre 8 y 64, finalmente se optó por $r: 16$, $alpha: 16$, tras comprobar que ofrecía buenos resultados de forma consistente.

3.6.2. Criterios de selección

Además de las métricas de pérdida, el principal criterio para seleccionar la mejor configuración fue el F1-score obtenido en el conjunto de validación, por su capacidad para reflejar el equilibrio entre precision y recall en un contexto de clases desbalanceadas. También se tuvo en cuenta la estabilidad del entrenamiento y la coherencia del comportamiento del modelo durante el fine-tuning.

3.7. Entrenamiento de los modelos

El proceso de entrenamiento se centró en adaptar distintos modelos de lenguaje a las tareas de clasificación propuestas en el reto. Se exploraron tanto arquitecturas tradicionales como enfoques basados en LLMs modernos. En total, se entrenaron tres variantes principales de modelos, cada una con su propia estrategia de entrada y objetivos:

- Un modelo transformer (Longformer), utilizado como línea base.
- Una variante con cadenas de razonamiento (Chain of Thought) utilizando DeepSeek R1.
- Dos modelos LLM (Qwen3 y LLaMA 3.1) entrenados con prompts directos e instrucciones claras.

El entrenamiento de los modelos se realizó utilizando dos entornos principales: Google Colab Pro, con acceso a GPUs como la T4, utilizado en pequeños experimentos, y el

entorno del laboratorio I2C, equipado con una GPU NVIDIA RTX 4070 de 12 GB de VRAM, donde se llevaron a cabo los entrenamientos principales de los modelos LLM.

3.7.1. Entrenamiento con Longformer

Como línea base, se entrenó el modelo **PlanTL-GOB-ES/longformer-base-4096-bne-es**, una versión del modelo roberta-base-bne adaptada al idioma español. Este modelo fue escogido por su capacidad para procesar secuencias largas y su , dada la elevada longitud de varias letras del dataset que superaban los 10.000 caracteres. El entrenamiento se centró únicamente en la clasificación binaria. Se aplicó una tasa de aprendizaje de $2e-5$, un total de 5 épocas. Aunque los resultados fueron útiles como punto de partida, el modelo mostró dificultades para generalizar en casos más ambiguos o sutiles. Esto sirvió como referencia base para contrastar las mejoras introducidas por los modelos de lenguaje de gran tamaño (LLMs) con técnicas de prompting.

3.7.2. Entrenamiento con Cadenas de Pensamiento CoT (DeepSeek R1)

En una segunda fase del trabajo, se exploró un enfoque más avanzado mediante el uso del modelo **DeepSeek-R1-8B**, aplicado a la tarea de clasificación binaria. Este experimento combinó el uso de un modelo de lenguaje de gran tamaño con una estrategia de razonamiento paso a paso (*Chain of Thought*), que consistía en proporcionar al modelo una breve justificación antes de mostrarle la etiqueta final. Para generar estas cadenas de razonamiento, se utilizaron dos modelos distintos:

- **GPT-4o**: Utilizando la API de OpenAI, se obtuvieron justificaciones detalladas para cada ejemplo, tratando de reflejar el motivo por el cual una letra debía considerarse misógina o no.
- **Salamandra**: Un modelo LLM local que permitió experimentar con la generación de cadenas de razonamiento en un entorno local, aunque con menor consistencia que GPT-4o.

Estas cadenas fueron generadas de forma automatizada, lo que introdujo ciertas limitaciones. En ocasiones, el modelo generador atribuía la misoginia a palabras o frases poco relevantes o erróneas, lo que provocaba una falta de alineación entre la justificación y la verdadera etiqueta del ejemplo. Esta falta de precisión afectó negativamente al rendimiento del modelo entrenado.

Instrucción

Analiza la siguiente letra de canción y determina si contiene contenido misógino.

Evalúa si incluye lenguaje, actitudes o mensajes que:

- Degraden o deshumanicen a las mujeres.

- Menosprecien a las mujeres de manera explícita o implícita.
- Refuercen estereotipos negativos o dañinos sobre las mujeres.
- Promuevan violencia física, emocional o sexual contra las mujeres.

Piensa cuidadosamente tu respuesta y crea paso a paso una chain of thoughts para dar una respuesta lógica.

Responde únicamente con '1' si la letra es misógina o con '0' si la letra no es misógina.

No proporciones ninguna explicación ni texto adicional.

Letra: lyrics

Respuesta: <think> reasoning </think> label

El entrenamiento se llevó a cabo empleando fine-tuning con adaptación eficiente mediante **LoRA**, usando una configuración con $r = 16$, $\alpha = 16$. La tasa de aprendizaje fue de $2e-5$ y se entrenó durante un máximo de 5 épocas, aplicando early stopping para evitar sobreajuste. Debido al tamaño del modelo y las limitaciones de memoria, se utilizó un esquema de acumulación de gradientes que permitía simular un batch efectivo de 8 instancias.




Figura 3.7: Eval loss durante el entrenamiento del modelo DeepSeek-R1

En la [Figura 3.7](#) se muestra la evolución de la pérdida de evaluación (eval loss) durante el entrenamiento de varias configuraciones del modelo DeepSeek-R1. Cada línea representa una combinación distinta de hiperparámetros, incluyendo variaciones en la tasa de aprendizaje, el valor de **alpha** y el origen del razonamiento (Salamandra o GPT4o).

Se observa que todas las configuraciones experimentan una disminución significativa de la pérdida en las primeras etapas del entrenamiento, lo que indica que los modelos están aprendiendo rápidamente a adaptarse a la tarea. En particular, las configuraciones que utilizaron un valor más alto de **alpha** = 32 (líneas naranja, verde y azul claro) mostraron una convergencia más rápida y alcanzaron las pérdidas más bajas. Esto sugiere que un mayor peso en las matrices de adaptación de LoRA favoreció un mejor ajuste del modelo.

al conjunto de validación, al menos en términos de la función de pérdida.

Sin embargo, es importante destacar que una menor pérdida de evaluación no garantiza necesariamente un mejor rendimiento en métricas como el F1-score o el recall. De hecho, algunas de estas configuraciones mostraron sobreajuste leve o inconsistencias en la clasificación final.

3.7.3. Entrenamiento con Qwen y LLaMA

Además del enfoque basado en razonamiento (Chain of Thought), se planteó de forma paralela el uso de modelos de lenguaje de gran tamaño con prompts más simples y directos, sin explicaciones intermedias. El objetivo era comparar si un enfoque instruccional más conciso, centrado únicamente en guiar al modelo hacia la clasificación final, podía resultar igualmente eficaz. Para ello, se seleccionaron los modelos **Qwen3-8B** y **LLaMA 3.1-8B**, ambos en sus versiones optimizadas para fine-tuning mediante la biblioteca Unsloth y cuantizados a 4 bits. Estas variantes fueron utilizadas para entrenar modelos instruccionales sin razonamiento paso a paso, explorando distintos formatos de prompt y combinaciones de hiperparámetros. Esta línea de experimentación permitió contrastar el rendimiento de modelos con y sin razonamiento explícito, y evaluar cuál de los dos enfoques se ajustaba mejor a ambas tareas.

Ambos modelos se entrenaron para la tarea binaria, mientras que solo Qwen3-8B fue utilizado en la tarea multiclase, ya que en las primeras pruebas demostró una mayor estabilidad y rendimiento. El entrenamiento se realizó aplicando **LoRA** con **r=16** y **alpha=16**, una tasa de aprendizaje de **2e-5** y durante un máximo de **10 épocas** aplicando early stopping. También se utilizó acumulación de gradientes para alcanzar un batch efectivo de **64**. Para orientar el modelo hacia la clasificación, se utilizaron prompts específicos que guiaban al modelo de forma clara. En el caso de la Tarea 1 (clasificación binaria), se probaron dos variantes de prompt, mientras que para la Tarea 2 (clasificación multiclase) se utilizó un único prompt.

- **Prompt Simple - Clasificación binaria:**

```
Analiza la siguiente letra de canción:
lyrics
Clasifica esta canción en una de las siguientes categorías:
Clase 1: No Misógina
Clase 2: Misógina
SOLUCION
La cancion es: Clase label
```

- **Prompt Detallado - Clasificación binaria:**

```
Analiza la siguiente letra de canción:
lyrics
```

Determina si el contenido transmite ideas, actitudes o expresiones que resulten ofensivas o denigrantes hacia las mujeres. Luego, clasificala en una de estas dos clases:

Clase 1: No Misógina

La letra no incluye contenido sexista, violento, degradante ni estereotipos negativos hacia las mujeres.

Clase 2: Misógina

La letra presenta elementos como cosificación, insultos, violencia, dominio o estereotipos negativos hacia las mujeres.

SOLUCION

La cancion es: Clase label

■ Prompt - Clasificación multiclase:

Analiza la siguiente letra de canción:

lyrics

Clasificala esta canción en una de las siguientes categorías:

Clase 1: No relacionada

Clase 2: Sexualización

Clase 3: Odio

Clase 4: Violencia

SOLUCION

La cancion es: Clase label

Para garantizar la coherencia en las salidas del modelo y evitar respuestas imprevistas, se modificó la capa de salida **lm_head** para restringir los tokens válidos exclusivamente a los correspondientes a las clases esperadas. Asimismo, se ajustó la función de pérdida para que solo el último token generado afectara al cálculo de la pérdida, enfocando al modelo únicamente en predecir la clase final.

Este diseño obtuvo el mejor rendimiento global. En particular, Qwen3-8B logró el mejor rendimiento de todos los modelos probados, destacando por su equilibrio entre precisión, recall y F1-score en ambas tareas.




Figura 3.8: Eval loss durante el entrenamiento de los modelos Qwen3 y LLaMA 3.1

En la [Figura 3.8](#) se muestra la evolución de la pérdida de evaluación (eval loss) durante el entrenamiento de distintas configuraciones de modelos LLMs, incluyendo Qwen3-8B, LLaMA 3.1 y Gemma 3. Cada curva representa una combinación de modelo, tipo de prompt Prompt 1 (Simple) o Prompt 2 (Detallado), tasa de aprendizaje (LR) y parámetros de LoRA (R y Alpha).

Se observa que la mayoría de las configuraciones logran una reducción inicial de la pérdida durante las primeras etapas del entrenamiento. Las configuraciones con **learning rate** = $1e-5$ tienden a mostrar un descenso más progresivo y estable, especialmente en el caso de Qwen3, con valores bajos y consistentes entre los pasos 40 y 100. En cambio, al aumentar la tasa de aprendizaje a $3e-5$, algunas curvas como la de Qwen3 con Prompt 0 (Sencillo) muestran signos claros de inestabilidad, con oscilaciones y aumento de la pérdida a partir de cierta etapa del entrenamiento, lo que sugiere un sobreajuste o una mala convergencia. El modelo Gemma 3 presenta una curva relativamente suave, aunque con un aumento de pérdida en las etapas finales. LLaMA 3.1 mantiene un comportamiento razonable pero menos eficiente que las variantes de Qwen3, tanto en pérdida mínima alcanzada como en estabilidad.

De forma general, estas gráficas reflejan que configuraciones con **Prompt Simple**, **alpha** = 16 y tasas de aprendizaje moderadas ofrecieron la mejor relación entre rapidez de convergencia y estabilidad. Sin embargo, al igual que en el caso de DeepSeek-R1, una menor pérdida de evaluación no siempre se traduce en mejores resultados en métricas clave como Precision, Recall o F1-score, por lo que estos valores deben interpretarse con cautela.

3.8. Analisis de resultados

En esta sección se presentan los resultados obtenidos tras evaluar los modelos entrenados sobre el conjunto de test. Además, se muestran matrices de confusión y se analizan los errores más frecuentes. Finalmente, se comparan los modelos y se discute cuál obtuvo el mejor rendimiento.

3.8.1. Resultados de Clasificación binaria

La [Tabla 3.2](#) presenta los resultados globales obtenidos por los diferentes modelos evaluados en la tarea de clasificación binaria. Se incluyen las métricas de precision, recall y F1-score macro, calculadas sobre el conjunto de test. Los mejores resultados en cada métrica se muestran en negrita.

Tabla 3.2: Resultados globales (clasificación binaria) en el conjunto de test.

Modelo	Precision	Recall	F1-score
Longformer base 4096 bne es	0.8031	0.8058	0.8044
DeepSeek R1 + CoT GPT4o	0.8186	0.8143	0.8164
DeepSeek R1 + CoT Salamandra	0.7669	0.7704	0.7686
LLaMA 3.1 8B Prompt Simple	0.8380	0.8101	0.8218
Qwen3 8B Prompt Simple	0.8423	0.8345	0.8382
Qwen3 8B Prompt Detallado	0.8138	0.8192	0.8164

Como se observa en la [Tabla 3.2](#), el modelo Qwen3 8B con prompt simple obtuvo el mejor rendimiento global, superando al resto de configuraciones en todas las métricas evaluadas. Esto sugiere que, en el contexto de esta tarea, una instrucción más directa y menos cargada de detalles favorece una mejor generalización del modelo. Por el contrario, el uso de un prompt detallado con el mismo modelo produjo un rendimiento ligeramente inferior, lo que refuerza la hipótesis de que un exceso de información puede introducir ruido innecesario.

También se observa que LLaMA 3.1 8B logró resultados competitivos, con un F1-score de 0.8218, lo que confirma su capacidad para manejar esta tarea con eficacia, aunque sin alcanzar el rendimiento de Qwen3. El modelo DeepSeek R1, combinado con cadenas de razonamiento (CoT) generadas por GPT-4o, ofreció un rendimiento sólido ($F1 = 0.8164$), comparable al prompt detallado de Qwen3. Sin embargo, su variante con explicaciones generadas por el modelo local Salamandra mostró una caída considerable en el rendimiento, lo que evidencia la importancia de la calidad del razonamiento introducido en los prompts.

Finalmente, el modelo base Longformer, aunque inferior a los LLMs en términos generales, sirvió como referencia inicial y mostró un rendimiento razonable, especialmente

considerando su menor tamaño y ausencia de técnicas avanzadas como prompting o razonamiento.

Para analizar con mayor detalle el comportamiento de los modelos en cada clase, la [Tabla 3.3](#) muestra los resultados por clase: *No Misógina* y *Misógina*.

Tabla 3.3: Resultados por clase para los modelos evaluados (conjunto de test, Tarea 1).

Modelo	Clase	Precision	Recall	F1-score
Longformer	No Misógina	0.8832	0.8771	0.8801
	Misógina	0.7231	0.7344	0.7287
DS R1 GPT4o	No Misógina	0.8946	0.8935	0.8941
	Misógina	0.7426	0.7352	0.7389
DS R1 Salamandra	No Misógina	0.8534	0.8532	0.8533
	Misógina	0.6804	0.6875	0.6839
LLaMA Simple	No Misógina	0.8740	0.9246	0.8986
	Misógina	0.8019	0.6953	0.7449
Qwen Simple	No Misógina	0.8721	0.9116	0.8915
	Misógina	0.8126	0.7578	0.7842
Qwen Detallado	No Misógina	0.8927	0.8805	0.8866
	Misógina	0.7348	0.7578	0.7462

El análisis por clase permite entender mejor las fortalezas y debilidades de cada modelo en la detección de contenido misógino. En general, todos los modelos obtienen mejores métricas en la clase No Misoginia, mientras que la detección de Misoginia resulta más desafiante, lo cual era esperable dado el desbalance presente en el dataset.

El modelo Qwen3 8B con prompt simple destaca como el más equilibrado, con un F1-score de 0.7842 en la clase Misoginia, lo que indica una buena capacidad para identificar correctamente los casos positivos sin sacrificar demasiada precisión. Por otro lado, su versión con prompt detallado obtiene un rendimiento ligeramente inferior, lo que refuerza la idea de que una instrucción más extensa no siempre mejora el desempeño.

En el caso de LLaMA 3.1, se observa un patrón interesante: alcanza un recall muy alto en la clase No Misoginia (0.9246), pero a costa de una menor capacidad para identificar correctamente los casos de Misoginia (recall = 0.6953).

DeepSeek R1 con razonamiento generado por GPT-4o obtiene resultados sólidos en ambas clases, aunque su rendimiento en la clase Misoginia (F1 = 0.7389) se sitúa por debajo del alcanzado por los otros modelos.

3.8.2. Resultados de Clasificación multiclase

La [Tabla 3.4](#) muestra el rendimiento global del modelo Qwen3 8B con prompt simple en la Tarea 2, correspondiente a la clasificación multiclase. Se incluyen las métricas macro-promediadas de precisión, exhaustividad (recall) y F1-score, calculadas sobre el conjunto de test.

Tabla 3.4: Resultados globales (macro-average) del modelo evaluado en la Tarea 2.

Modelo	Precision macro	Recall macro	F1-score macro
Qwen Simple	0.4909	0.4888	0.4892

El valor de F1-score macro obtenido (0.4892) indica que, si bien el modelo es capaz de distinguir parcialmente entre las cuatro categorías propuestas (No relacionada, Sexualización, Odio y Violencia), su rendimiento aún es limitado, especialmente teniendo en cuenta que se trata de un problema con clases desbalanceadas y más difíciles de definir.

A pesar de ello, el desempeño supera el umbral del azar (0.25 en un problema de 4 clases), lo que demuestra que el modelo ha aprendido ciertos patrones útiles. No obstante, aún queda margen de mejora, tanto en la calidad de los datos como en el diseño del prompt y la arquitectura del modelo.

Tabla 3.5: Resultados por clase para el modelo evaluado (Tarea 2, conjunto de test).

Clase	Precision	Recall	F1-score
No relacionada (0)	0.7547	0.7619	0.7583
Sexualización (1)	0.7654	0.7126	0.7381
Odio (2)	0.1935	0.2308	0.2105
Violencia (3)	0.2500	0.2500	0.2500

Los resultados por clase presentados en la [Tabla 3.5](#) permiten observar con mayor precisión el comportamiento del modelo en cada una de las categorías definidas en la Tarea 2. Como era previsible, el modelo muestra un mejor desempeño en las clases mayoritarias: No relacionada y Sexualización.

En concreto, la clase No relacionada alcanza un F1-score de 0.7583, mientras que Sexualización obtiene 0.7381, evidenciando una buena capacidad del modelo para identificar contenido que no presenta indicios de misoginia o que está centrado en la representación sexualizada. Por el contrario, las clases Odio y Violencia, mucho menos frecuentes en el dataset, presentan F1-scores notablemente bajos (0.2105 y 0.2500, respectivamente). Estas cifras reflejan la dificultad del modelo para identificar correctamente estos casos.

Estos resultados refuerzan la necesidad de explorar técnicas adicionales para el manejo del desbalance, como el ajuste de pesos en la función de pérdida o la recolección de ejemplos

más representativos.

3.8.3. Matrices de confusión

En esta sección se presentan las matrices de confusión correspondientes a los distintos modelos evaluados en la Tarea 1 (clasificación binaria) y la Tarea 2 (clasificación multiclase). Estas visualizaciones permiten analizar de forma más intuitiva los errores de predicción cometidos por cada sistema y comprobar en qué medida cada clase fue correctamente identificada.

Matriz de confusión de Modelo Longformer

La [Figura 3.9](#) muestra la matriz de confusión correspondiente al modelo Longformer base, evaluado en la Tarea 1 (clasificación binaria). Se observa que el modelo presenta un comportamiento equilibrado entre ambas clases, aunque con un número notable de errores. En total, se clasificaron correctamente 257 ejemplos como No Misóginos y 94 como Misóginos. Sin embargo, también se produjeron 34 falsos negativos, es decir, letras misóginas clasificadas erróneamente como no misóginas, y 36 falsos positivos, donde el modelo etiquetó como misóginas letras que no lo eran.




Figura 3.9: Matriz de confusión del modelo Longformer (Tarea 1).

Matriz de confusión de Modelo DeepSeek R1 con GPT-4o

La [Figura 3.10](#) muestra la matriz de confusión del modelo DeepSeek R1 utilizando cadenas de pensamiento generadas por GPT-4o. El modelo presenta un rendimiento ligeramente superior al del Longformer, especialmente en la identificación de ejemplos de la clase No Misógina. Se observa una reducción en el número de falsos positivos (31 frente a 36 en el modelo anterior), lo que indica una mejor precisión al no etiquetar erróneamente letras no misóginas como misóginas. Sin embargo, el número de falsos negativos se mantiene en 34, lo que sugiere que el modelo sigue teniendo dificultades para identificar algunos casos de misoginia más sutiles o ambiguos.




Figura 3.10: Matriz de confusión del modelo DeepSeek R1 con CoT por GPT4o (Tarea 1).

Matriz de confusión de Modelo DeepSeek R1 con Salamandra 8B

La [Figura 3.11](#) muestra la matriz de confusión del modelo DeepSeek R1 cuando se entrenó utilizando cadenas de pensamiento generadas por el modelo local Salamandra. En comparación, el rendimiento es inferior: se incrementan tanto los falsos positivos (43) como los falsos negativos (40).

Este deterioro sugiere que la calidad del razonamiento intermedio incluido en los ejemplos influye notablemente en la capacidad del modelo para clasificar correctamente. En particular, las cadenas generadas localmente parecen introducir ruido o explicaciones menos alineadas con las etiquetas reales.




Figura 3.11: Matriz de confusión del modelo DeepSeek R1 con CoT por Salamandra (Tarea 1).

Matriz de confusión de Modelo LLaMA 8B con Prompt Simple

La [Figura 3.12](#) muestra la matriz de confusión del modelo LLaMA 3.1 8B con prompt simple. Este modelo presenta un rendimiento equilibrado, destacando por su alta precisión en la clase No Misógina, donde apenas comete 22 falsos positivos.

Sin embargo, persiste una dificultad para identificar correctamente letras misóginas, con 39 falsos negativos, una cifra algo superior a la de otros modelos. Este resultado sugiere que incluso con una instrucción directa y simple, LLaMA 3.1 es capaz de captar patrones relevantes en el texto, lo que lo convierte en una opción competitiva sin requerir prompts complejos.




Figura 3.12: Matriz de confusión del modelo LLaMA 3.1 8B con Prompt Simple (Tarea 1).

Matriz de confusión de Modelo Qwen 8B con Prompt Simple

La [Figura 3.13](#) muestra la matriz de confusión del modelo Qwen3 8B con prompt simple. Este modelo es el que logra el mejor equilibrio entre ambas clases en la Tarea 1, con únicamente 26 falsos positivos y 31 falsos negativos.

Destaca especialmente su capacidad para mantener bajo el error en la clase minoritaria (Misógina), una tarea en la que otros modelos suelen tener más dificultades. Este comportamiento sugiere que Qwen3, incluso con instrucciones simples, es capaz de capturar de forma eficaz las señales semánticas asociadas a cada clase. Su rendimiento consistente en ambas clases lo convierte en el modelo más robusto de todos los evaluados, demostrando no solo buena precisión global, sino también una mayor sensibilidad hacia ejemplos menos frecuentes.




Figura 3.13: Matriz de confusión del modelo Qwen3 8B con Prompt Simple (Tarea 1).

Matriz de confusión de Modelo Qwen 8B con Prompt Detallado

La [Figura 3.14](#) muestra la matriz de confusión del modelo Qwen3 8B con prompt detallado. Aunque el modelo mantiene un rendimiento muy competitivo, con los mismos 31 falsos negativos que la versión con prompt simple, el número de falsos positivos aumenta a 35. Este incremento sugiere que el uso de un prompt más elaborado no necesariamente mejora la capacidad discriminativa del modelo, y podría incluso introducir ambigüedades o sobreexplicaciones que dificultan la predicción en textos no misóginos. A pesar de este leve aumento en errores, el modelo sigue mostrando un desempeño sólido y equilibrado entre clases, lo que refuerza la idea de que Qwen3 8B es un modelo robusto.




Figura 3.14: Matriz de confusión del modelo Qwen3 8B Prompt Detallado (Tarea 1).

Matriz de confusión de Modelo Qwen 8B para Clasificación Multiclase

En la [Figura 3.15](#) se muestra la matriz de confusión del modelo Qwen3 8B con prompt simple aplicado a la tarea multiclase. El modelo logra un buen desempeño en las clases más representadas, especialmente en No relacionada y Sexualización, donde concentra la mayoría de los aciertos. Sin embargo, se aprecia una mayor confusión en las clases minoritarias, como Odio y Violencia. Este patrón es coherente con el desbalance del dataset y refleja la dificultad de detectar tipos específicos de misoginia menos frecuentes.




Figura 3.15: Matriz de confusión del modelo Qwen3 8B Prompt Simple (Tarea 2).

En concreto, la clase 0 (No relacionada) y la clase 1 (Sexualización) muestran una alta tasa de aciertos, con pocos errores de confusión entre ellas. Por el contrario, las clases 2 (Odio) y 3 (Violencia) presentan predicciones más dispersas entre otras clases, lo que sugiere que el modelo tiene dificultades para identificar patrones específicos cuando el número de ejemplos disponibles es limitado. Esto refuerza la importancia de considerar técnicas adicionales de balanceo o generación de datos sintéticos en futuras versiones del sistema.

3.8.4. Ensemble

Una vez entrenados y evaluados los modelos individuales con mejor rendimiento en la Tarea 1, se optó por implementar una estrategia de ensemble por votación mayoritaria, con el objetivo de combinar sus predicciones y obtener un sistema más robusto.

El procedimiento consistió en aplicar los cuatro modelos seleccionados sobre el conjunto

de test y almacenar sus predicciones. Para cada ejemplo, la predicción final fue determinada mediante votación mayoritaria. En los casos donde se produjo un empate, se desempató seleccionando la predicción del modelo con mayor F1-score. Este enfoque busca aprovechar las fortalezas complementarias de los modelos.

La [Tabla 3.6](#) muestra un ejemplo de cómo se agruparon las predicciones de los cuatro modelos para cada instancia del conjunto de test. También se indica la predicción final obtenida tras aplicar la votación mayoritaria.

Tabla 3.6: Ejemplo de predicciones y desempate con F1-score.

ID	Modelo 1	Modelo 2	Modelo 3	Modelo 4	Pred Final
T1_TEST_0007	0	1	1	0	0
T1_TEST_0086	1	1	0	0	1
T1_TEST_0031	0	1	1	0	0
T1_TEST_0077	0	0	1	1	0
T1_TEST_0117	1	1	1	0	1
T1_TEST_0155	1	0	1	0	1

Cabe destacar que los modelos están ordenados de izquierda a derecha según su rendimiento individual (F1-score), siendo el Modelo 1 el que obtuvo mejores resultados y el Modelo 4 el de menor rendimiento.

Comparativa de rendimiento

Para evaluar la efectividad de la estrategia de ensemble, se calcularon las métricas de F1-score de cada uno de los modelos participantes por separado, así como la del sistema combinado.

Como puede observarse en la [Tabla 3.7](#), el sistema de ensemble obtiene un rendimiento competitivo, situándose en el segundo mejor resultado. Aunque su F1-score (0.8320) no supera al mejor modelo por separado (Qwen3-8B con Prompt simple), ofrece una solución más robusta y estable al combinar los puntos fuertes de varios sistemas.

Tabla 3.7: F1-score de cada modelo individual frente al sistema de ensemble

Model	F1-Score
Qwen3-8B (Prompt Simple)	0.8359
Qwen3-14B (Prompt Simple)	0.8224
Qwen3-8B (Prompt Detallado)	0.8137
Llama3.1-8B (Prompt Simple)	0.8121
Ensemble	0.8320

Este resultado evidencia que el enfoque de ensemble permite suavizar errores individua-

les, especialmente en casos donde los modelos tienen comportamientos complementarios.

3.9. Análisis de errores

El análisis de errores se ha centrado en los dos modelos con mejor rendimiento en cada una de las tareas planteadas. El objetivo de este apartado es identificar y caracterizar los errores más representativos, con el fin de comprender en qué contextos y por qué fallan los modelos. Para ello, se han analizado ejemplos reales mal clasificados, agrupados por tipo de error (falsos positivos y falsos negativos), y se han formulado hipótesis sobre las posibles causas.

3.9.1. Errores en Clasificación binaria

- **Ejemplo Falso Positivo:**

Canción (fragmento): '...quiere que lo hagamos en la discoteca...
la prepa se trepa..'

Etiqueta real: No Misógina

Predicción: Misógina

Comentario: El modelo interpreta un discurso de empoderamiento femenino como contenido misógino, Este tipo de errores refleja una falta de contexto cultural, donde se penaliza el lenguaje sin evaluar la intención del mensaje.

- **Ejemplo Falso Negativo:**

Canción (fragmento): '...yo debí ser más dura contigo y dejar que murieras de frío...'

Etiqueta real: Misógina

Predicción: No Misógina

Comentario: Aunque la canción parece una queja sentimental, algunas frases reflejan ideas de castigo y desprecio. El modelo no lo detecta, probablemente porque el tono es menos directo como en letras más explícitas.

3.9.2. Errores en Clasificación multiclase

Como puede observarse en la matriz de confusión [Figura 3.15](#), la clase Violencia (clase 3) fue correctamente identificada solo en 4 ocasiones de un total de 16 ejemplos. De forma similar, la clase Odio (clase 2) alcanzó apenas 6 aciertos sobre 26. Esta baja capacidad de

identificación sugiere que el modelo no ha logrado capturar adecuadamente los patrones asociados a estos tipos de misoginia.

Posibles causas de los errores

Las razones más probables de estos errores son:

- **Desbalance de clases:** Las clases Odio y Violencia tienen una representación muy baja en el dataset, lo que dificulta que el modelo aprenda patrones significativos.
- **Ambigüedad del lenguaje:** Muchas letras contienen metáforas o referencias culturales que pueden ser interpretadas de diferentes formas, lo que complica la clasificación.
- **Dificultad para distinguir matices sutiles:** Las diferencias entre clases como *Odio* y *Violencia* pueden ser muy sutiles en algunos casos.

Propuestas de mejora para reducir errores

A partir del análisis de errores observados, se proponen distintas líneas de actuación para mejorar el rendimiento de los modelos, especialmente en la Tarea 2:

- **Aumento de datos para clases minoritarias:** Diseñar estrategias de recolección o generación de nuevas instancias que refuercen las clases menos representadas, como *Odio* y *Violencia*. Esto podría incluir técnicas de *data augmentation* textual.
- **Uso de aprendizaje por refuerzo o feedback humano:** Implementar mecanismos de validación colaborativa, donde usuarios evalúen las predicciones y se utilice esa información como retroalimentación para refinar el modelo.
- **Enriquecimiento semántico con modelos externos:** Complementar la entrada al modelo con predicciones de herramientas como detectores de emociones, análisis de sentimiento o clasificadores temáticos, que puedan aportar contexto adicional para mejorar la predicción.

3.10. Resultados Oficiales de la Tarea

Este trabajo participó oficialmente en el reto MiSonGyny 2025, organizado en el marco del workshop IberLEF (Iberian Languages Evaluation Forum), celebrado durante la conferencia SEPLN 2025. Durante la fase de desarrollo, se probaron múltiples configuraciones de

modelos de lenguaje de gran tamaño (LLMs) aplicando técnicas de fine-tuning. Tras evaluar el rendimiento sobre el conjunto de validación propio, se seleccionaron los siguientes modelos como runs oficiales:

- **Tarea 1 (clasificación binaria):** Modelo *Qwen3-8B* con prompt simple.
- **Tarea 2 (clasificación multiclase):** Modelo *Qwen3-8B* con prompt simple.

El conjunto de test oficial fue proporcionado por la organización, contenía 527 ejemplos para la Tarea 1 (clasificación binaria) y 293 ejemplos para la Tarea 2 (clasificación multiclase). Las métricas finales fueron calculadas por la organización una vez enviados los resultados. Los resultados oficiales se muestran en la [Tabla 3.8](#), donde se incluyen los resultados obtenidos por el modelo en ambas tareas, junto con los de otros participantes.

Participante	Tarea	F1-score	Ranking
Equipo A	Tarea 1	0.8811	1
I2C	Tarea 1	0.8359	2
Equipo B	Tarea 1	0.8279	3
Equipo C	Tarea 1	0.8051	4
Media general	Tarea 1	0.7812	–
Equipo A	Tarea 2	0.5895	1
I2C	Tarea 2	0.5613	2
Equipo B	Tarea 2	0.5429	3
Equipo C	Tarea 2	0.4946	4
Media general	Tarea 2	0.4993	–

Tabla 3.8: Resultados oficiales publicados por la organización del reto MiSonGyny 2025.

3.10.1. Publicación de resultados

Los resultados obtenidos se han recogido en un artículo científico titulado **Fine-Tuned LLM Approach to Detect Misogyny in Spanish Song Lyrics**, actualmente en proceso de publicación en el workshop IberLEF 2025. Este artículo forma parte del laboratorio CLEF (Conference and Labs of the Evaluation Forum), una iniciativa que agrupa contribuciones científicas revisadas por pares y presentadas en talleres de evaluación como IberLEF.

El artículo describe en detalle la metodología aplicada, los experimentos realizados y los resultados obtenidos en el marco del reto MiSonGyny 2025. Está previsto que sea publicado en las actas del evento y estará disponible públicamente en la plataforma CEUR-WS¹. Además, se ha incluido como Anexo en esta memoria para su consulta.

¹<https://ceur-ws.org/>

Conclusiones y Trabajo Futuro

4.1. Conclusiones

Los objetivos definidos al inicio del trabajo han sido alcanzados satisfactoriamente. Se han entrenado y ajustado mediante fine-tuning diversos modelos para la tarea de clasificación de contenido sensible, incluyendo tanto arquitecturas basadas en Transformers como modelos de lenguaje de gran tamaño (LLMs). A través del análisis de los resultados, se ha demostrado que los LLMs comprenden mejor el contexto complejo, superando en rendimiento a los modelos tradicionales. Además, la evaluación se ha realizado en el marco de la competición oficial MiSonGyny 2025, donde se ha obtenido el segundo puesto en ambas tareas, lo que respalda la efectividad y robustez de la solución propuesta.

4.1.1. Resumen de los Hallazgos

Los LLMs demostraron un rendimiento claramente superior, con una mejora del 4,2% en F1-score respecto al baseline desarrollado con Longformer. Su capacidad para interpretar lenguaje implícito o matices los convierte en herramientas muy potentes para abordar tareas complejas. El modelo Qwen3, finetuneado con LoRA y ajustado mediante diferentes estrategias de prompting, fue el que obtuvo mejores resultados en ambas tareas. Sin embargo, se identificaron errores frecuentes en casos de misoginia sutil, así como una notable dificultad en la clasificación de las clases minoritarias en la tarea multiclase, agravada por el fuerte desbalance del dataset.

También se observó que el uso de prompts detallados o con razonamiento no siempre garantizó una mejora sistemática del rendimiento, lo que indica que el diseño del prompt debe adaptarse cuidadosamente al modelo y a la tarea concreta. Las estrategias de prompting simples, combinadas con un buen fine-tuning, resultaron ser especialmente eficaces en este contexto.

4.1.2. Contribuciones y Consideraciones Éticas

Este trabajo evidencia el potencial de los LLMs en el análisis automatizado de texto sensible. Además de contribuir con una solución técnica robusta, se ha generado un conjunto de resultados que pueden servir como referencia para futuras investigaciones en el área de clasificación de contenido tóxico en español.

Desde un punto de vista ético, se refuerza la necesidad de una supervisión humana constante y contextualizada en sistemas de moderación de contenido basados en inteligencia artificial. Las decisiones tomadas por los modelos, aunque técnicamente precisas, pueden tener implicaciones sociales relevantes, especialmente cuando se trata de señalar discursos problemáticos en productos culturales como la música.

En definitiva, este trabajo demuestra que los modelos de lenguaje de gran tamaño son herramientas potentes y accesibles si se entrenan y ajustan adecuadamente, pueden desempeñar un papel importante en la identificación automatizada de formas de violencia simbólica en entornos reales.

4.2. Trabajo Futuro

En el futuro, sería interesante ampliar el alcance del sistema más allá de la misoginia y explorar otros tipos de discursos de odio presentes en letras de canciones, como el racismo o la homofobia. Esto permitiría abordar de forma más completa la violencia simbólica que puede estar presente en la música.

Además, con el objetivo de mejorar el rendimiento del sistema en la Tarea 2 (clasificación multiclase), se propone aplicar técnicas específicas para mitigar los efectos del desbalance en las clases menos representadas, como ‘Odio’ o ‘Violencia’. Algunas líneas de trabajo en este sentido podrían incluir técnicas de data augmentation, generación automática de ejemplos sintéticos mediante modelos generativos, o el uso de loss functions adaptadas, que penalicen con mayor intensidad los errores en clases minoritarias.

Por otro lado, se propone el desarrollo de una aplicación web o móvil en la que los usuarios puedan introducir letras de canciones y obtener una predicción automática del sistema. Esta plataforma incorporaría un sistema de validación colaborativa: los usuarios podrían indicar si consideran correcta o incorrecta la predicción ofrecida, lo que permitiría recolectar ejemplos reales con anotaciones humanas. Estos nuevos datos podrían utilizarse para reentrenar o ajustar el modelo para adaptarse a distintos estilos, géneros o contextos culturales.

4.3. Planificación Temporal del Trabajo Realizado

A continuación se presenta una estimación del tiempo dedicado a las distintas fases del proyecto, incluyendo tanto el aprendizaje como el desarrollo, la participación en la competición y la redacción de los documentos.

La planificación se resume en la Tabla 4.1.

Tabla 4.1: Distribución del tiempo invertido en el desarrollo del TFG.

Actividad	Horas
Análisis de la competición <i>MiSonGyny 2025</i>	5
Estudio de fundamentos teóricos:	70
- Machine Learning, Transformers, PLN, métricas de evaluación	
- Transfer Learning y técnicas de Fine Tuning	
Formación técnica y herramientas:	90
- Python, PyTorch, LLMs para NLP, uso de librerías necesarias	
- Cursos del laboratorio I2C	
- Participación en competición interna sobre PNL en el laboratorio I2C	
- Curso de prompting impartido en la Universidad de Huelva	
- Familiarización con entornos y $\text{\LaTeX}$	
Desarrollo del sistema y experimentación:	160
- Procesado de datos, implementación de código, entrenamiento, pruebas y optimización	
- Validación de resultados y análisis de errores	
Redacción y revisión del artículo científico	50
Elaboración de la memoria final del proyecto	55
Total estimado	430

Esta tabla refleja el número de horas dedicadas a cada actividad, siendo el grueso de las horas invertidas en el desarrollo del sistema y la experimentación.

También se han dedicado 160 horas al estudio y formación técnica para adquirir los conceptos necesarios para el desarrollo del proyecto.

Una vez finalizada la competición, se ha dedicado un total de 50 horas a la redacción y revisión del artículo científico. Finalmente, se dedicaron 55 horas para la elaboración de la memoria final del proyecto, donde se ha documentado todo el proceso.

Referencias

- [1] Tom M. Mitchell. *Machine Learning*. McGraw-Hill, 1997.
- [2] Google cloud. *¿Qué es el aprendizaje automático?* URL: <https://cloud.google.com/learn/what-is-machine-learning>.
- [3] Paloma Recuero de los Santos. *Tipos de aprendizaje en Machine Learning*. 2021. URL: <https://telefonicatech.com/blog/que-algoritmo-elegir-en-ml-aprendizaje>.
- [4] IBM. *¿Qué es el aprendizaje supervisado?* Consultado el 26 de marzo de 2025. 2023. URL: <https://www.ibm.com/es-es/topics/supervised-learning>.
- [5] IBM. *¿Qué es el aprendizaje no supervisado?* Consultado el 26 de marzo de 2025. 2023. URL: <https://www.ibm.com/es-es/topics/unsupervised-learning>.
- [6] IBM. *¿Qué es el aprendizaje de refuerzo?* Consultado el 26 de marzo de 2025. 2025. URL: <https://www.ibm.com/es-es/think/topics/reinforcement-learning>.
- [7] Daniella Coleman. *Tipos de aprendizaje automático*. 2023. URL: <https://serverspace.io/es/about/blog/introduction-to-machine-learning>.
- [8] Amazon Web Services. *¿Qué es la clasificación de textos?* URL: <https://aws.amazon.com/what-is/text-classification/>.
- [9] Yann LeCun, Yoshua Bengio y Geoffrey Hinton. “Deep learning”. En: *Nature* 521.7553 (2015), págs. 436-444.
- [10] Juan Ignacio Bagnato. *Épocas underfitting y overfitting*. 2017. URL: <https://www.coursera.org/mx/articles/ai-vs-deep-learning-vs-machine-learning-beginners-guide>.
- [11] Adithya Prasad Pandelu. *Batch size*. 2024. URL: <https://medium.com/@bhatadithya54764118/day-48-training-neural-networks-hyperparameters-batch-size-epochs-712c57d9e30c>.
- [12] Jason Brownlee. *Learning rate*. 2024. URL: <https://machinelearningmastery.com/understand-the-dynamics-of-learning-rate-on-deep-learning-neural-networks/>.
- [13] Piyush Kashyap. *Early stopping*. 2024. URL: <https://medium.com/%40piyushkashyap045/early-stopping-in-deep-learning-a-simple-guide-to-prevent-overfitting-1073f56b493e>.
- [14] Ramazan Gençay. *Early stopping*. Consultado el 26 de marzo de 2025. 2001. URL: https://www.researchgate.net/figure/Early-stopping-based-on-cross-validation_fig1_3302948.
- [15] Ashish Vaswani et al. *Attention Is All You Need*. 2023. arXiv: 1706.03762 [cs.CL]. URL: <https://arxiv.org/abs/1706.03762>.
- [16] OpenAI. *GPT-4*. Publicado el 14 de marzo de 2023. 2023. URL: <https://openai.com/index/gpt-4-research/>.

- [17] Hugo Touvron et al. *LLaMA: Open and Efficient Foundation Language Models*. 2023. arXiv: [2302.13971 \[cs.CL\]](https://arxiv.org/abs/2302.13971). URL: <https://arxiv.org/abs/2302.13971>.
- [18] Qwen team. *Qwen3: Think Deeper, Act Faster*. Publicado el 29 de abril de 2025. 2025. URL: <https://qwenlm.github.io/blog/qwen3/>.
- [19] DeepSeek-AI et al. *DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning*. 2025. arXiv: [2501.12948 \[cs.CL\]](https://arxiv.org/abs/2501.12948). URL: <https://arxiv.org/abs/2501.12948>.
- [20] Alberto Tomás Delso Vicente, Marisol Carvajal Camperos y Daniel Ángel Corral De La Mata. “La evolución Del Procesamiento Del Lenguaje Natural Y Su Influencia En La Inteligencia Artificial: Una revisión Y líneas De investigación Futura”. En: *European Public amp; Social Innovation Review* (2024). URL: <https://epsir.net/index.php/epsir/article/view/782>.
- [21] Jim Holdsworth. *¿Qué es el procesamiento de lenguaje natural "PLN"?*. 2024. URL: <https://www.ibm.com/mx-es/think/topics/natural-language-processing>.
- [22] Pablo Huet. *Técnicas clave para el procesamiento de texto en NLP*. Publicado 4 de julio de 2024. 2024. URL: <https://openwebinars.net/blog/tecnicas-clave-para-procesamiento-texto-nlp/>.
- [23] alarcon7a. *¿Qué son los embeddings?* Publicado 16 de abril de 2025. 2025. URL: <https://platzi.com/blog/embeddings-nlp/>.
- [24] Astriz Ruiz. «Zero-shot» y «Few-shot» y «chain of thought»: así trabajan los ingenieros el prompting para IA. Publicado 3 de octubre de 2024. 2024. URL: <https://marketing4ecommerce.net/zero-shot-few-shot-y-chain-of-thought-prompting-ia/>.
- [25] Sebastian Ruder. “Neural Transfer Learning for Natural Language Processing”. En: *arXiv preprint arXiv:1903.11260* (2019). URL: <https://arxiv.org/abs/1903.11260>.
- [26] César de Pablo Sánchez María Hernández Rubio. *Aplicando Transfer Learning a modelos de lenguaje natural*. Publicado el 25 de marzo de 2021. 2021. URL: <https://www.bbvaiafactory.com/es/applying-transfer-learning-to-natural-language-models/>.
- [27] Edward J. Hu et al. *LoRA: Low-Rank Adaptation of Large Language Models*. 2021. arXiv: [2106.09685 \[cs.CL\]](https://arxiv.org/abs/2106.09685). URL: <https://arxiv.org/abs/2106.09685>.
- [28] Simplilearn. *Ensemble Learning: Boost Accuracy with Multiple Models*. Publicado el 4 de mayo de 2025. 2025. URL: <https://www.simplilearn.com/ensemble-learning-article>.
- [29] Issa Memari. *Precision, Accuracy and F1 Score for Multi-Label Classification*. Publicado el 12 de enero de 2021. 2021. URL: <https://medium.com/synthesio-engineering/precision-accuracy-and-f1-score-for-multi-label-classification-34ac6bdfb404>.
- [30] Profesor Data. *La Matriz de Confusión: ¡claramente explicada!* Publicado el 7 de agosto de 2020. 2020. URL: <https://profesordata.com/2020/08/07/evaluando->

- [los-modelos-de-clasificacion-en-aprendizaje-automatico-la-matriz-de-confusion-claramente-explicada/](#).
- [31] Laura Casanovas-Buliart, Priscila Alvarez-Cueva y Carlos Castillo and. “Evolution over 62 years: an analysis of sexism in the lyrics of the most-listened-to songs in Spain”. En: *Cogent Arts & Humanities* 11.1 (2024), pág. 2436723. DOI: [10.1080/23311983.2024.2436723](#). eprint: [https://doi.org/10.1080/23311983.2024.2436723](#). URL: [https://doi.org/10.1080/23311983.2024.2436723](#).
- [32] Danqing Chen et al. *Tuning Into Bias: A Computational Study of Gender Bias in Song Lyrics*. 2025. arXiv: [2409.15949 \[cs.CL\]](#). URL: [https://arxiv.org/abs/2409.15949](#).
- [33] Ricardo Calderón-Suarez et al. “Enhancing the Detection of Misogynistic Content in Social Media by Transferring Knowledge From Song Phrases”. En: *IEEE Access* 11 (2023), págs. 13179-13190. DOI: [10.1109/ACCESS.2023.3242965](#).
- [34] Paolo Rosso Elisabetta Fersini Debora Nozza. “AMI @ EVALITA2020: Automatic Misogyny Identification”. En: *Proceedings of the 7th evaluation campaign of Natural Language Processing and Speech tools for Italian (EVALITA 2020)*. Ed. por Valerio Basile et al. Online: CEUR.org, 2020.
- [35] Francisco Rodríguez-Sánchez y Jorge Carrillo-de-Albornoz y Laura Plaza y Adrián Mendieta-Aragón y Guillermo Marco-Remón y Maryna Makeienko y María Plaza y Julio Gonzalo y Damiano Spina y Paolo Rosso. “Overview of EXIST 2022: sE-Xism Identification in Social neTworks”. En: *Procesamiento del Lenguaje Natural* 69.0 (2022), págs. 229-240. ISSN: 1989-7553. URL: [http://journal.sepln.org/sepln/ojs/ojs/index.php/pln/article/view/6443](#).
- [36] Helena Gómez-Adorno et al. “Overview of HOMO-MEX at IberLEF 2024: Hate Speech Detection Towards the Mexican Spanish speaking LGBT+ Population”. En: *Procesamiento del Lenguaje Natural* 73 (2024), págs. 393-405.
- [37] Iz Beltagy, Matthew E. Peters y Arman Cohan. *Longformer: The Long-Document Transformer*. 2020. arXiv: [2004.05150 \[cs.CL\]](#). URL: [https://arxiv.org/abs/2004.05150](#).
- [38] Lukas Biewald. *Experiment Tracking with Weights and Biases*. Software available from wandb.com. 2025. URL: [https://www.wandb.com/](#).

A.1. Repositorio de código en GitHub y modelos en Hugging Face

Se ha habilitado un repositorio público en GitHub que contiene todos los recursos necesarios para reproducir este trabajo. El repositorio incluye el dataset utilizado en el proyecto (en su versión preprocesada), así como varios cuadernos en formato Jupyter Notebook con los pasos realizados: exploración de datos, preprocesamiento, entrenamiento de modelos, evaluación y análisis de resultados.

El repositorio puede consultarse en el siguiente enlace:

<https://github.com/atoroj/Misogyny-Lyrics-Detection-LLMs>

Además, se ha incluido un archivo `README.md` con una guía detallada sobre la estructura del proyecto y las instrucciones necesarias para replicar los experimentos descritos en esta memoria.

Por último, los modelos entrenados en este trabajo han sido publicados en la plataforma Hugging Face y están disponibles para su descarga y uso desde los siguientes enlaces:

- <https://huggingface.co/atorojaen/DeepSeek-R1-MiSonGyny>
- <https://huggingface.co/atorojaen/Llama3.1-MiSonGyny>
- <https://huggingface.co/atorojaen/Qwen3-MiSonGyny>
- <https://huggingface.co/atorojaen/Qwen3-MiSonGyny-Task2>

A.2. Aplicación Web para la Visualización y Prueba del Modelo

Como parte complementaria del trabajo, se ha desarrollado una aplicación web sencilla que permite cargar el modelo entrenado y utilizarlo para clasificar nuevas letras de canciones. Esta herramienta La aplicación ha sido implementada utilizando **Gradio**, una biblioteca que permite construir interfaces web de forma rápida a partir de unas pocas líneas de código en Python. Esto permite visualizar cómo se comporta el modelo y sus respuestas.

El modelo integrado en la aplicación corresponde a la versión entrenada de **DeepSeek-R1**. Este modelo destaca por generar respuestas más detalladas y expresivas, ya que incorpora una cadena de razonamiento (chain-of-thought) antes de ofrecer la predicción final. Sin embargo, este enfoque más creativo puede conllevar una ligera disminución en la precisión. Aun así, su inclusión en la aplicación permite visualizar cómo un modelo de lenguaje con capacidad de explicación puede aportar valor.

Tecnologías Utilizadas

- **Backend:** Desarrollado en Python, el backend se encarga del preprocesamiento del texto de entrada y de la inferencia con el modelo.
- **Frontend:** Interfaz generada con **Gradio**, una herramienta que permite construir aplicaciones web interactivas de forma sencilla..
- **Despliegue:** La aplicación se aloja temporalmente en Hugging Face Spaces, una plataforma que permite ejecutar aplicaciones con soporte para GPU y acceder a ellas fácilmente desde el navegador.

Acceso a la Aplicación

Debido a requisitos técnicos y a la disponibilidad limitada de recursos, el acceso a la herramienta será temporal. Puede visitarse desde el siguiente enlace:

<https://huggingface.co/spaces/atorojaen/MisogynyDetector>

Ejemplo de uso generado por GPT4o

Texto introducido:

[Letra de 'Contigo es hogar']

[Verso 1]

Déjame soñar con tus historias

Sentarme a escuchar lo que te da memoria

Déjame cuidar tus cicatrices
Sin querer borrarlas, solo hacerlas menos grises
Y déjame aprender de tu manera de mirar
Ese mundo que despiertas cuando empiezas a confiar
Quiero compartirte mis locuras
Y verte libre sin que pierdas tu ternura
Quiero celebrarte cada día
Con palabras nuevas que se escriben con tu risa
...

Salida del modelo:

1. La letra se centra en expresar amor y devoción hacia una persona, sin hacer distinciones de género, lo que evita la degradación o deshumanización de las mujeres.
2. No hay menosprecio explícito o implícito hacia las mujeres; el enfoque está en la constancia del amor y la devoción a lo largo del tiempo.
3. La letra no refuerza estereotipos negativos o dañinos hacia las mujeres, ya que se centra en sentimientos de cariño y aprecio mutuo.
4. No se promueve la violencia hacia las mujeres; el mensaje es de respeto y admiración hacia la persona amada.

Respuesta final: 0

Capturas de pantalla




Figura A.1: Captura de pantalla de la App

A.3. Paper de la Competición MiSonGyny

A continuación se incluye el artículo científico titulado **Fine-Tuned LLM Approach to Detect Misogyny in Spanish Song Lyrics**, elaborado en el marco de la competición MiSonGyny 2025 del workshop IberLEF 2025.

Este trabajo ha sido aceptado para su publicación dentro del laboratorio CLEF (Conference and Labs of the Evaluation Forum), que reúne contribuciones científicas revisadas por pares en talleres de evaluación. El artículo será publicado en las actas del evento, disponibles en la plataforma CEUR-WS.

La publicación recoge los principales aspectos metodológicos, experimentales y de evaluación abordados a lo largo de este Trabajo de Fin de Grado.

I2C-UHU at MiSonGyny 2025: Fine-Tuned LLM Approach to Detect Misogyny in Spanish Song Lyrics

Antonio Toro-Jaén, Victoria Pachón-Alvarez, Jacinto Mata-Vázquez and
Angel Barroso-Romero

I2C Research Group, University of Huelva, Spain

Abstract

This work presents the approach developed by the I2C Research Group for the MiSonGyny 2025 shared task at IberLEF 2025, which focused on the detection of misogynistic content in Spanish-language song lyrics. The main contribution consists in the use of prompt-based fine-tuning applied to large language models (LLMs), combined with a parameter-efficient adaptation using LoRA. For Task 1 (binary classification), several LLMs were evaluated and integrated into an ensemble model based on majority voting, with tie-breaking performed using cumulative F1-scores. For Task 2 (multiclass classification), a single model was fine-tuned to classify lyrics into four categories of misogynistic content. The proposed system was evaluated on both tasks, achieving F1-scores of 83.59% and 56.13%, respectively, and obtaining the second-best results in both cases.

Keywords

Large language models (LLMs), LoRA, Ensemble, Prompt-based fine-tuning, Misogynistic content,

1. Introduction

Detecting hate speech in online and cultural content is a growing challenge in natural language processing (NLP), especially when such content is embedded in creative forms like music. Song lyrics, in particular, present complex linguistic constructions, figurative language, and subtle messages making it particularly difficult to accurately detect misogynistic messages. Music has a strong influence on public perceptions and social dynamics. When misogynistic language is present in lyrics, it can contribute to the reinforcement and normalization of harmful gender stereotypes. Identifying and addressing such content is therefore essential to promote more inclusive and respectful representations.

This paper describes our participation in the MiSonGyny 2025 [1] task at IberLEF 2025 [2], focused on the detection of misogynistic content in Spanish-language song lyrics. The task was divided into two subtasks: Task 1, which involved binary classification (misogynistic vs. not related), and Task 2, which required multiclass classification of the type of misogynistic expression (sexualization, violence, hate, or not related).

Recent advances in Large Language Models (LLMs) [3] and prompt-based training [4] have opened new possibilities for adapting models to highly contextual and nuanced tasks. This paper presents our participation in MiSonGyny 2025, where we applied LLM-based techniques to address both subtasks of the challenge.

2. Related Works

Recent studies have shown that song lyrics can reinforce gender-based stereotypes and sexist attitudes. As music is a widely consumed cultural product, the messages embedded in lyrics may influence social perceptions of gender roles. In recent years, researchers have applied natural language processing (NLP) techniques to detect sexism and bias in lyrics and to measure their evolution over time.

A notable example is the work by Casanovas-Buliart (2024) [5], who conducted a large-scale analysis of over 2,800 of the most-listened-to songs in Spain from 1960 to 2022. They used supervised machine

IberLEF 2025, September 2025, Zaragoza, Spain

✉ antonio.toro@alu.uhu.es (A. Toro-Jaén); vpachon@dti.uhu.es (V. Pachón-Alvarez); mata@dti.uhu.es (J. Mata-Vázquez);
angel.barroso880@alu.uhu.es (A. Barroso-Romero)



© 2025 Copyright for this paper by its authors. Use permitted under Creative Commons License Attribution 4.0 International (CC BY 4.0).

learning models trained on manually annotated paragraphs to classify songs as sexist or non-sexist. Their findings revealed that 51% of the songs contained sexist expressions, and that the presence of such content has increased significantly in recent years, especially in Spanish-language songs available on streaming platforms. They also identified dominant themes such as hypersexualization, objectification, and control over women.

Chen et al. (2025) [6] applied topic modeling (BERTopic) and gender bias metrics (SC-WEAT) to over 500,000 English lyrics. Their results showed that lyrics have increasingly associated women with terms related to appearance and sexuality, while men were more often linked to power and agency, highlighting a systematic gender imbalance in musical discourse.

Calderón-Suárez et al. (2023) [7] proposed a data augmentation strategy using misogynistic fragments from song lyrics to improve misogyny detection systems in social media. Their results suggest that music lyrics contain rich and diverse expressions of misogyny that can support the development of more robust detection models, particularly for Spanish-language data.

Beyond lyrics-focused work, related shared tasks have addressed sexism and misogyny detection in user-generated content. AMI @ EVALITA 2020 [8] targeted misogyny and aggressiveness in Italian tweets. Similarly, EXIST 2022 [9] offered multilingual benchmarks in English and Spanish for both binary and fine-grained sexism classification on social media, emphasizing the complexity of capturing implicit forms of bias.

Building on these trends, the HOMO-MEX 2024 [10] included a subtask specifically focused on detecting LGBT+phobic content in Spanish song lyrics. The dataset combined over 1,200 annotated lyrics using both automatic methods (via the Genius API and LyricScraper) and manual selection informed by members of the LGBT+ community. The task highlights how challenging it is to detect hate speech when it appears in figurative or poetic language, since these forms often hide harmful content behind metaphors or artistic expressions. Successfully identifying them requires models capable of deep contextual understanding and subtle interpretation. In contrast to prior studies that focus on general sexism or use lyrics as a resource for other tasks, the present work addresses the direct detection of misogyny in Spanish song lyrics. We apply a fine-tuned large language model to perform both binary and multiclass classification, aiming to bridge the gap between NLP methods and the cultural analysis of lyrical content.

3. Task and Dataset Description

The MiSonGyny 2025 challenge includes two independent classification tasks focused on detecting and categorizing misogynistic content in Spanish-language song lyrics. Each task is framed as a supervised learning [11] problem using manually labeled datasets.

3.1. Task 1: Binary Classification

The objective of Task 1 is to classify each song lyric as either misogynistic or non-misogynistic. The definitions for the two labels are as follows:

- **Misogynistic (M):** Lyrics that include explicit or implicit content that denigrates, disrespects, or expresses hatred, sexual objectification, or control towards women.
- **Non-misogynistic (NM):** Lyrics that do not contain any such content, regardless of whether or not they refer to gender or women.

A dataset of 2,105 entries was provided for this task, all in Spanish, with some containing short English phrases. The dataset was manually split in two stages:

1. An 80/20 split was performed to separate the full dataset into training and test sets.
2. The training portion (80%) was further split 80/20 into a new training set and a validation set.

The final distribution of classes across the splits is shown in Table 1.

Table 1

Classes distribution for Task 1

Class	Train Dataset	Valid Dataset	Test Dataset
NM	935	234	293
M	411	103	128
Total	1346	337	421

3.2. Task 2: Multiclass Classification

The second task is a four-class classification problem. Each lyric was labeled according to the specific type of misogynistic expression:

- **Sexualization (S):** Expressions that imply or mention sexual behavior, use sexual terms, or contain suggestive remarks.
- **Violence (V):** Expressions that involve threats, acts of physical harm, or verbal abuse.
- **Hate (H):** Expressions that use offensive or biased language, or convey disdain or antagonism toward individuals or groups.
- **Not Related (NR):** Expressions that don't fit into the other categories and contain no sexual, violent, or hateful content.

This dataset contains 1,168 lyrics, and was split using the same two-stage stratified strategy:

1. 80% for training and 20% for testing.
2. Then 80%/20% split on the training data for the validation data.

The final distribution of classes across the splits is shown in Table 2.

Table 2

Classes distribution for Task 2

Class	Train Dataset	Valid Dataset	Test Dataset
NR	337	84	105
S	278	70	87
V	82	21	26
H	50	12	16
Total	747	187	234

4. Methodology

This work explores the use of Large Language Models (LLMs) [12] to detect and classify misogynistic content in Spanish-language song lyrics. The methodology was designed to address two distinct tasks: a binary classification (Task 1) and a multiclass classification (Task 2), both framed as supervised text classification problems.

To solve these tasks, several open-access LLMs were fine-tuned using a parameter-efficient approach based on Low-Rank Adaptation (LoRA). [13] The training process included custom output constraints and data balancing strategies to adapt the models to the specific nature of lyric-based misogyny detection.

All models were trained using a NVIDIA GeForce RTX 4070 GPU with 12 GB of VRAM. While this setup allowed for efficient experimentation, the available memory, training time, and computational budget imposed significant constraints. Without the use of parameter-efficient fine-tuning techniques such as LoRA and 4-bit model quantization, it would not have been feasible to train and evaluate 8B-scale language models. These strategies were therefore essential to reduce both memory usage and training time, enabling the implementation of multiple model variants within the available resources.

4.1. Data preprocessing

Before training, several preprocessing steps were applied to clean and normalize the data. All lyrics were first lowercased, and irrelevant content, such as punctuation marks, artist names, song titles, and non-lyrical text, was removed. Table 3 shows an example before and after preprocessing.

Table 3

Example of original and preprocessed lyrics used in the training pipeline.

Original	Preprocessed
[Intro-Scratch] Flor de vida, flor de vida... Los paisajes cambian Un chico de carácter agradable [?] de suicidio, puede grabarlo en vídeo ...	flor de vida flor de vida los paisajes cambian un chico de carácter agradable de suicidio puede grabarlo en vídeo

For Task 1, the original class labels were 'M' (misogynistic) and 'NM' (non-misogynistic). For Task 2, the labels were 'NR' (not related), 'S' (sexualization), 'H' (hate), and 'V' (violence). All labels were subsequently mapped to integer values.

To address class imbalance, random oversampling was applied to the training set in both tasks. In Task 1, the original distribution consisted of 935 non-misogynistic and 411 misogynistic samples in the training set. After oversampling, the minority class was increased to 600 samples, reducing the imbalance while avoiding excessive duplication. In Task 2, the initial distribution was 337 for 'NR', 278 for 'S', 82 for 'V', and 50 for 'H'. After oversampling, the 'V' and 'H' classes were increased to 150 and 100 samples respectively, achieving a more balanced representation without fully equalizing all classes.

4.2. Model Selection and Training Setup

To solve both tasks, Large Language Models (LLMs) were used with multilingual capabilities and support for long-context input. All models were used in their bnb 4-bit quantized versions for efficient fine-tuning using Unsloth [14], which enables fast loading and compatibility with LoRA-based adaptation. The selected models were:

- **DeepSeek-R1-Distill-Llama-8B-unsloth-bnb-4bit:** A distilled version of DeepSeek-R1, fine-tuned on LLaMA 3.1 outputs. It offers strong reasoning performance with reduced computational demands. [15]
- **Meta-Llama-3.1-8B-bnb-4bit:** Meta’s multilingual LLM optimized for alignment and dialogue, with robust performance in Spanish and other supported languages. [16]
- **Qwen3-8B-Base-unsloth-bnb-4bit:** Alibaba’s third-generation model, designed for strong instruction-following and multilingual capabilities, with high efficiency at 8B scale. [17]

All three models were evaluated in Task 1, while only Qwen3 was used for Task 2 due to its superior performance in the binary classification task.

Training Configuration

Different training configurations were applied depending on the model. For DeepSeek-R1, fine-tuning was carried out for 5 epochs with an effective batch size of 8. The training set contained 1,526 examples, resulting in approximately 190 steps per epoch and a total of 950 training steps. The learning rate was set to $2e-5$, and the optimizer used was 8-bit AdamW. The training process included early stopping with a patience of 3 and checkpoint saving every 25 steps. LoRA was configured with rank = 16 and alpha = 16.

For Qwen3 and LLaMA 3.1, training was performed for 10 epochs in both tasks where they were used, with an effective batch size of 64. The learning rate remained at $2e-5$, using the same LoRA

configuration as above. The optimizer used was also 8-bit AdamW. A linear learning rate schedule was applied, and early stopping based on validation loss was enabled with a patience of 3. Checkpoints were saved every 25 steps, and the best model was restored automatically based on evaluation loss. In Task 2, only Qwen3 was used, and it followed the same configuration as in Task 1.

Prompting Strategy

Different prompt templates were designed for each model to optimize classification performance. For **DeepSeek-R1**, an instruction-based prompt was used that explicitly listed the criteria for identifying misogynistic content and encouraged the model to reason step by step using a chain of thought format. The exact prompt is shown below:

Instruccion

Analiza la siguiente letra de canción y determina si contiene contenido misógino. Evalúa si incluye lenguaje, actitudes o mensajes que:

- Degraden o deshumanicen a las mujeres.
- Menosprecien a las mujeres de manera explícita o implícita.
- Refuercen estereotipos negativos o dañinos sobre las mujeres.
- Promuevan violencia física, emocional o sexual contra las mujeres.

Piensa cuidadosamente tu respuesta y crea paso a paso una chain of thoughts para dar una respuesta logica.

Responde únicamente con "1" si la letra es misógina o con "0" si la letra no es misógina. No proporciones ninguna explicación ni texto adicional.

Letra:

{lyrics}

Respuesta:

<think>{reasoning}</think> {label}

For **Qwen3** and **LLaMA 3.1**, classification was prompted using a more direct and concise template:

Analiza la siguiente letra de canción: {lyrics}

Clasifica esta canción en una de las siguientes categorías:

Clase 1: No Misógina

Clase 2: Misógina

SOLUCION

La cancion es: Clase {label}

Additionally, for Task 2, where lyrics had to be classified into four categories, we used the following instruction:

Analiza la siguiente letra de canción: {lyrics}

Clasifica esta canción en una de las siguientes categorías:

Clase 1: No Relacionada

Clase 2: Sexualizacion

Clase 3: Violencia

Clase 4: Odio

SOLUCION

La cancion es: Clase {label}

In addition, a more detailed variant of the prompt was tested, including explicit descriptions of each class and examples of misogynistic content. However, this version led to slightly worse performance, likely due to increased token length and greater generation variability. To ensure consistency and prevent unexpected outputs, the `lm_head` layer of Qwen3 and LLaMA was modified to restrict predictions

to only the token IDs corresponding to the allowed class labels (1 and 2 for Task 1, and 1 to 4 for Task 2). Furthermore, the training setup was adapted so that only the final token in the sequence contributed to the loss function, ensuring that the model focused solely on predicting the class label rather than attempting to reconstruct the entire input. This adjustment improved both training efficiency and classification stability.

Tokenization

All models were used with their corresponding tokenizers. Given the nature of song lyrics, which often include repeated phrases, annotations, or lengthy verses, special attention was paid to input length. A maximum sequence length of 4,096 tokens was defined. Lyrics exceeding the limit were truncated from the end of the sequence, preserving the start of the prompt and lyric. This ensured uniform input size across the dataset.

Reproducibility

To ensure reproducibility, all experiments were conducted using the same random seed (3407) and consistent dataset splits. The code used for model training is available at:

<https://github.com/atoroj/Misogyny-Lyrics-Detection-LLMs>

This repository includes the notebooks, dataset, and everything necessary to reproduce the results presented in this work.

4.3. Models Performance

This section presents the final evaluation results for both tasks as part of the official MiSonGyny 2025 competition. After training and selecting the best-performing models using test data extracted from the provided training set, the predictions for each task were submitted. The results were evaluated using official competition metrics, macro-averaged F1 score, precision and recall, as shown in Table 4.

Table 4

Evaluation metrics (F1, Precision, Recall).

Model	F1-Score	Precision	Recall
Task 1			
DeepSeek-R1 8B	0.72022	0.77090	0.70224
Llama3.1 8B	0.81209	0.81630	0.80833
Qwen3 8B	0.83592	0.83774	0.83417
Task 2			
Qwen3 8B	0.56131	0.57093	0.55614

4.3.1. Ensemble

To improve performance in Task 1, an ensemble strategy was explored by combining the predictions of four independently fine-tuned models. The ensemble output was determined by majority voting over the predictions of the four models. If three or more agreed on the same label, that prediction was accepted. [18]

In cases of a 2 vs 2 tie, the resolution strategy was based on a weighted F1-score voting. Specifically, the sum of the individual F1-scores of the models voting for each class was computed, and the class with the higher cumulative F1 was selected.

Table 5 shows the F1-scores obtained by each individual model, as well as the final F1-score achieved by the ensemble.

Table 5
Ensemble of models.

Model	F1-Score
Qwen3-8B (Prompt 1)	0.8359
Qwen3-8B (Prompt 2)	0.8137
Llama3.1-8B (Prompt 1)	0.8121
Qwen3-14B (Prompt 1)	0.8224
Ensemble	0.83201

Although the ensemble did not outperform the best individual model, it still achieved a highly competitive F1-score and improved the stability of predictions.

5. Results

The final evaluation results are presented in Table 6 and Table 7 . The table displays the usernames, F1-scores, and ranking positions for the top five participants in each task. All metrics were calculated over a hidden test set using official evaluation scripts.

In Task 1 (Binary Classification), our system obtained an F1-score of 0.8359, ranking 2nd place overall. Our approach demonstrated solid and consistent performance across all instances.

Table 6
Task 1: Binary Classification – Top 5 Rankings

Rank	Username	F1-score
1	jstoledo	0.88114
2	I2C-Vega (Ours)	0.83592
3	carlosdf	0.82795
4	mapachepunk	0.80514
5	eliasurios30	0.80394

In Task 2 (Multiclass Classification), which involved detecting the specific type of misogynistic content, our model achieved an F1-score of 0.5613, also placing 2nd among all submissions.

Table 7
Task 2: Multiclass Classification – Top 5 Rankings

Rank	Username	F1-score
1	jstoledo	0.58954
2	I2C-Vega (Ours)	0.56131
3	eliasurios30	0.54299
4	luisramos07	0.49462
5	danielacl	0.49287

The strong performance across both tasks highlights the effectiveness of the proposed methodology. Our model ranked above other systems, demonstrating the relevance of model selection, careful prompting, and parameter-efficient fine-tuning in this type of linguistic and socially sensitive classification.

6. Error Analysis

The confusion matrix for Task 1 is shown in Figure 1. The model demonstrates a strong ability to detect non-misogynistic lyrics (Class 0), with 267 true negatives and only 26 false positives. However,

31 misogynistic lyrics (Class 1) were misclassified as non-misogynistic, revealing a vulnerability in detecting subtle or implicit forms of misogyny. These false negatives often involved figurative language, metaphorical expressions, or indirect verbal aggression that the model failed to interpret as harmful.

On the other hand, some false positives appear to stem from lyrics expressing passion, sexuality, or emotional intensity, particularly from a female perspective. This suggests that the model may occasionally confuse female empowerment or sensual expression with misogynistic stereotypes.

Table 8 illustrates selected examples of misclassified lyrics from Task 1.




Figure 1: Confusion matrix for Task 1, 0 for No Misogynistic and 1 for Misogynistic.

Table 8

Examples of misclassified lyrics.

Lyrics	Predicted Label	True Label
"Quiere que lo hagamos en la discoteca... la G te come, pero no te besa..."	M	NM
"Si tú quieres un atajo y lo quieres por abajo, yo te llevo bien callao..."	M	NM
"Haber sido siempre tu abrigo yo debí ser más dura contigo y dejar que murieras de frío..."	NM	M
"Si me provocas te voy a besar los ojos te voy a tomar del pelo te voy a hacer llorar de un beso..."	NM	M

Figure 2 shows the confusion matrix for Task 2. It shows that the model performs reasonably well in distinguishing Not Related lyrics (Class 0) and Sexualization (Class 1), with 80 and 62 correct predictions, respectively. But significantly lower performance in identifying Violence (Class 2) and Hate (Class 3). Only 6 and 4 instances were correctly classified, respectively, while many others were predicted as Class 0 or Class 1. This may be attributed to the data imbalance affecting the Violence and Hate classes, as well as the semantic overlap among hate speech, violent expressions, and sexualized content.




Figure 2: Confusion matrix for Task 2, 0 for Not Related, 1 for Sexualization, 2 for Violence and 3 for Hate.

7. Conclusion

In this paper, we presented our system for the IberLEF 2025-MiSonGyny task, which addressed the detection of misogynistic content in Spanish-language song lyrics. We participated in both Task 1 (binary classification) and Task 2 (multiclass classification), achieving robust and competitive results in both. Our approach was based on fine-tuning multilingual Large Language Models (LLMs), with prompt-based fine-tuning.

These findings highlight the potential of LLMs trained with prompt-based fine-tuning to learn task behavior efficiently, especially when provided with well-structured input formats. In future works, we plan to explore larger or instruction-tuned models to enhance generalization, apply data augmentation for underrepresented classes, and investigate the use of ensemble methods to further improve performance.

In conclusion, our study shows that using carefully designed prompts to fine-tune large language models is an effective way to address complex classification tasks, especially when working with creative and culturally rich texts such as song lyrics. The results highlight how a careful combination of good data preparation, efficient training, and focused evaluation can lead to strong performance on real-world language challenges.

Declaration on Generative AI

During the preparation of this work, the authors used GPT-4o in order to: Text Translation, Grammar and spelling checks. After using these tools, the authors reviewed and edited the content as needed and takes full responsibility for the publication’s content.

References

- [1] T. Alcántara, M. Soto, C. Macías, O. García-Vázquez, A. Espinosa-Juárez, H. Calvo, J. E. Valdez-Rodríguez, E. Felipe-Riveron, Overview of MiSonGyny at IberLEF 2025: Misogyny Speech Detection in Spanish Language Song Lyrics, *Procesamiento del Lenguaje Natural* 75 (2025).
- [2] J. Á. González-Barba, L. Chiruzzo, S. M. Jiménez-Zafra, Overview of IberLEF 2025: Natural Language Processing Challenges for Spanish and other Iberian Languages, in: *Proceedings of the Iberian Languages Evaluation Forum (IberLEF 2025)*, co-located with the 41st Conference of the Spanish Society for Natural Language Processing (SEPLN 2025), CEUR-WS. org, 2025.
- [3] H. Naveed, A. U. Khan, S. Qiu, M. Saqib, S. Anwar, M. Usman, N. Akhtar, N. Barnes, A. Mian, A comprehensive overview of large language models, 2024. URL: <https://arxiv.org/abs/2307.06435>. arXiv:2307.06435.
- [4] P. Liu, W. Yuan, J. Fu, Z. Jiang, H. Hayashi, G. Neubig, Pre-train, prompt, and predict: A systematic survey of prompting methods in natural language processing, 2021. URL: <https://arxiv.org/abs/2107.13586>. arXiv:2107.13586.
- [5] L. Casanovas-Buliart, P. Alvarez-Cueva, C. C. and, Evolution over 62 years: an analysis of sexism in the lyrics of the most-listened-to songs in Spain, *Cogent Arts & Humanities* 11 (2024) 2436723. URL: <https://doi.org/10.1080/23311983.2024.2436723>. doi:10.1080/23311983.2024.2436723. arXiv:<https://doi.org/10.1080/23311983.2024.2436723>.
- [6] D. Chen, A. Satish, R. Khanbayov, C. M. Schuster, G. Groh, Tuning into bias: A computational study of gender bias in song lyrics, 2025. URL: <https://arxiv.org/abs/2409.15949>. arXiv:2409.15949.
- [7] R. Calderón-Suarez, R. M. Ortega-Mendoza, M. Montes-Y-Gómez, C. Toxqui-Quitl, M. A. Márquez-Vera, Enhancing the detection of misogynistic content in social media by transferring knowledge from song phrases, *IEEE Access* 11 (2023) 13179–13190. doi:10.1109/ACCESS.2023.3242965.
- [8] P. R. Elisabetta Fersini, Debora Nozza, Ami @ evalita2020: Automatic misogyny identification, in: V. Basile, D. Croce, M. Di Maro, L. C. Passaro (Eds.), *Proceedings of the 7th evaluation campaign of Natural Language Processing and Speech tools for Italian (EVALITA 2020)*, CEUR.org, Online, 2020.
- [9] F. R.-S. y Jorge Carrillo-de-Albornoz y Laura Plaza y Adrián Mendieta-Aragón y Guillermo Marco-Remón y Maryna Makeienko y María Plaza y Julio Gonzalo y Damiano Spina y Paolo Rosso, Overview of exist 2022: sexism identification in social networks, *Procesamiento del Lenguaje Natural* 69 (2022) 229–240. URL: <http://journal.sepln.org/sepln/ojs/ojs/index.php/pln/article/view/6443>.
- [10] H. Gómez-Adorno, G. Bel-Enguix, H. Calvo, S. Ojeda-Trueba, S. T. Andersen, J. Vásquez, S. Ojeda-Trueba, T. Alcántara, M. Soto, C. Macías, Overview of HOMO-MEX at IberLEF 2024: Hate Speech Detection Towards the Mexican Spanish speaking LGBT+ Population, *Procesamiento del Lenguaje Natural* 73 (2024) 393–405.
- [11] S. B. Kotsiantis, Supervised machine learning: A review of classification techniques, *Informatica* 31 (2007) 249–268.
- [12] W. X. Zhao, K. Zhou, J. Li, T. Tang, X. Wang, Y. Hou, Y. Min, B. Zhang, J. Zhang, Z. Dong, Y. Du, C. Yang, Y. Chen, Z. Chen, J. Jiang, R. Ren, Y. Li, X. Tang, Z. Liu, P. Liu, J.-Y. Nie, J.-R. Wen, A survey of large language models, 2025. URL: <https://arxiv.org/abs/2303.18223>. arXiv:2303.18223.
- [13] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, W. Chen, Lora: Low-rank adaptation of large language models, 2021. URL: <https://arxiv.org/abs/2106.09685>. arXiv:2106.09685.
- [14] M. H. Daniel Han, U. team, Unsloth, 2023. URL: <http://github.com/unslothai/unsloth>.
- [15] D. AI, Deepseek llms, <https://huggingface.co/DeepSeek-AI>, 2025.
- [16] M. Llama, Llama ai, <https://huggingface.co/meta-llama>, 2025.
- [17] A. Qwen, Qwen llms, <https://huggingface.co/Qwen>, 2025.
- [18] G. Abramowitz, Model independence in multi-model ensemble prediction, *Australian Meteorological and Oceanographic Journal* 59 (2010) 3–6. doi:10.22499/2.5901.002.