

Universidad de Huelva



DETECCIÓN DE MISOGINIA EN LETRAS DE CANCIONES MEDIANTE LARGE LANGUAGE MODELS (LLMS)

Grado en Ingeniería Informática


Autor: Antonio Toro Jaén

Tutores: Victoria Pachón Álvarez

Jacinto Mata Vázquez

Índice

- Motivación
- Objetivos
- Metodología
- Análisis de errores
- Participación en un reto
- Conclusiones
- Trabajo Futuro
- Demo



Laura Casanovas-Buliar (2024).

Motivación

- Recientes estudios demuestran un aumento en el sexismo en la música.
- El 51% de las canciones más escuchadas en España entre 1960 y 2022 contienen contenido sexista.
- La escala y el volumen actual de canciones hacen inviable una revisión manual.
- La aplicación de modelos de lenguaje permite detectar patrones asociados a la misoginia.

Objetivos

General

- Desarrollar dos sistemas de detección automática aplicando técnicas de procesamiento del lenguaje natural y modelos de lenguaje de gran tamaño (LLMs): uno orientado a identificar discursos misóginos en letras de canciones en español, y otro enfocado en determinar el tipo de contenido misógino presente, clasificándolo en una de cuatro categorías específicas.

Específicos


- Estudiar técnicas de aprendizaje automático y profundo aplicadas a la clasificación de textos.
- Implementar y ajustar modelos de lenguaje usando fine-tuning, prompting y LoRA.
- Comparar el rendimiento de los modelos mediante métricas de evaluación.
- Validar el sistema participando en el reto MiSonGyny (IberLEF 2025).


Dataset

- Se trabajó con **dos** conjuntos de datos independientes.
- Tarea binaria: **2105 instancias.**
- Tarea multiclase: **1170 instancias.**
- Cada una incluía la canción completa junto con **etiquetas** como Autor, Verso, Coro.


ID	Canción	Etiqueta
T1_0001	[Letra de "No Me Enseñaste"] [Verso 1] Llama no importa la hora que yo estoy aquí ...	No Misógina
T1_0002	Pachin! Viajera, te vas de puerta en puerta Buscando quien te quiera ...	Misógina
T2_0001	Que no me falte tu cuerpo jamás, jamás Ni el calor de tu forma de amar, jamás... Ni la ternura de tu despertar ...	No Relacionada
T2_0003	[Coro:] Ay me cansé de rogarle (yo ah) [Verso 1:] Me cansé de rogarle ...	Odio
T2_0004	[Letra de "Te Conozco"] [Verso 1] Te conozco desde el pelo hasta la punta de los pies ...	Sexualización
T2_0008	[Letra de "Hermanita"] Aventura [Verso 1] Como pasan los años, ayer éramos niños	Violencia

Metodología aplicada






Palabras más frecuentes en las letras etiquetadas como Misógina



Distribución de clases Binaria





Distribución de clases Multiclase

Análisis de datos

- Las distribuciones muestran un **fuerte desbalance** de clases, tanto en binaria como multiclase.
- El número medio de caracteres por canción fue de **1531.30**, con un mínimo de **45** y un máximo de **11720** caracteres.

Oversampling

- Se aplicó **random oversampling** para equilibrar las clases minoritarias y mejorar el rendimiento del modelo
- En la tarea binaria, se aumento del 44% en la clase **Misógina**.
- En la tarea multiclase, las clases minoritarias **Violencia** y **Odio** se incrementaron aproximadamente un 83 % y 100 %, respectivamente.



Preprocesamiento

- Se normalizó el texto: minúsculas, eliminación de signos, símbolos y nombres de artistas.
- Las etiquetas fueron **remapeadas** a **valores numéricos** para ambas tareas.
- Se construyeron entradas completas tipo **instrucción + texto + clase esperada**.

Texto Original	Texto Preprocesado
[Intro-Scratch] Flor de vida, flor de vida... Los paisajes cambian Un chico de carácter agradable [?] de suicidio, puede grabarlo en vídeo ...	flor de vida flor de vida los paisajes cambian un chico de carácter agradable de suicidio puede grabarlo en vídeo

Cadenas de pensamiento (Chain of Thoughts)

- Técnica de prompting que guía al modelo a **razonar paso a paso** antes de generar una respuesta final.
- Este proceso se llevó a cabo utilizando modelos LLM a través de **Salamandra y GPT-4o**.
- Se empleó un **prompt guiado** para generar cadenas de razonamiento concisas (4-5 pasos) que justificaran la etiqueta asignada a cada letra.

Instrucción

Analiza la siguiente letra de canción y explica en una cadena de pensamiento concisa (aproximadamente 4-5 líneas o pasos principales) por qué la letra justifica la etiqueta **<etiqueta>**

Letra:

<letra>

Considera si la letra incluye:

- Degradación/deshumanización de mujeres.
- Menosprecio explícito/implícito hacia las mujeres.
- Refuerzo de estereotipos negativos/dañinos hacia las mujeres.
- Promoción de violencia hacia las mujeres.

Responde **ÚNICA Y EXCLUSIVAMENTE** con el texto de la cadena de pensamiento.

NO incluyas **NADA** adicional.

Modelos utilizados

DeepSeek R1

Buen rendimiento en tareas de razonamiento paso a paso.

Ideal para experimentar con cadenas de pensamiento (Chain of Thought).



LLaMA 3

Elegido por su arquitectura moderna y su popularidad en la comunidad.

Ofreció buenos resultados en tareas de clasificación, especialmente al usar instrucciones claras.



Qwen 3

Fue el modelo con mejor rendimiento del proyecto.

Su arquitectura más reciente (abril 2025) y su capacidad de generalización favorecieron su desempeño en ambas tareas.



Low-Rank Adaptation (LoRA)

- Evita entrenar todos los parámetros.
- Reduce necesidad de almacenamiento.
- Mejora la eficiencia en fine-tuning de modelos muy grandes.
- LoRA ayuda a preservar el conocimiento previo del modelo base, reduciendo el riesgo de olvido catastrófico.



Entrenamiento con cadenas de pensamiento

- Se utilizó el modelo **DeepSeek-R1 8B** junto a cadenas generadas automáticamente.
- El entrenamiento se realizó con **LoRA** ($r = 16$, $\alpha = 16$), **learning rate** $2e-5$ y **early stopping** y un **batch size** de 8.
- El razonamiento (CoT) buscaba mejorar la toma de decisiones, pero su calidad afectó al rendimiento.

Instrucción:

Analiza la siguiente letra de canción y determina si contiene contenido misógino. Evalúa si incluye lenguaje, actitudes o mensajes que:

- Degraden o deshumanicen a las mujeres.
- Menosprecien a las mujeres de forma explícita o implícita.
- Refuercen estereotipos negativos o dañinos.
- Promuevan violencia física, emocional o sexual.

Piensa cuidadosamente tu respuesta y crea paso a paso una chain of thoughts para dar una respuesta lógica.

Responde solo con '1' si la letra es misógina o con '0' si no lo es.

No proporciones ninguna explicación adicional.

Letra: `<letra>`

Respuesta: `<think> <razonamiento> </think> <etiqueta>`

Entrenamiento con prompt simple y detallado

- Se probaron **dos** variantes de prompt: uno simple y otro más detallado.
- Se utilizaron los modelos **Qwen3-8B** y **LLaMA 3.1-8B**.
- Entrenamiento con **LoRA** ($r = 16$, $\alpha = 16$), **learning rate** $2e-5$, **early stopping** y **batch size** de 64.
- Permitted comparar rendimiento y estabilidad frente a modelos con razonamiento.

Analiza la siguiente letra de canción:

`<letra>`

Clasifica esta canción en una de las siguientes categorías:

Clase 1: No Misógina

Clase 2: Misógina

SOLUCION La cancion es: Clase `<etiqueta>`

Analiza la siguiente letra de canción:

`<letra>`

Determina si el contenido transmite ideas, actitudes o expresiones que resulten ofensivas o denigrantes hacia las mujeres. Luego, clasifícala en una de estas dos clases:

Clase 1: No Misógina La letra no incluye contenido sexista, violento, degradante ni estereotipos negativos hacia las mujeres.

Clase 2: Misógina La letra presenta elementos como cosificación, insultos, violencia, dominio o estereotipos negativos hacia las mujeres.

SOLUCION La cancion es: Clase `<etiqueta>`

Entrenamiento con prompt simple tarea multiclase

- Solo se utilizó **Qwen3-8B**, por su mejor estabilidad en las primeras pruebas.
- Se aplicó **LoRA** ($r = 16$, $\alpha = 16$), **learning rate** $2e-5$, con **early stopping** y **batch size** de 64.
- El prompt incluía una instrucción clara, siguiendo el diseño que mejor funcionó en la tarea binaria.

Analiza la siguiente letra de canción:

`<letra>`

Clasifica esta canción en una de las siguientes categorías:

Clase 1: No relacionada

Clase 2: Sexualización

Clase 3: Odio

Clase 4: Violencia

SOLUCION La canción es: Clase `<etiqueta>`

Resultados del entrenamiento

Modelo	Precision	Recall	F1-Score
Longformer (Baseline)	0.8031	0.8058	0.8044
DeepSeek R1 + CoT GPT4o	0.8186	0.8143	0.8164
DeepSeek R1 + CoT Salamandra	0.7669	0.7704	0.7686
LLaMA 3.1 8B Prompt Simple	0.8380	0.8101	0.8218
Qwen3 8B Prompt Simple	0.8423	0.8345	0.8382
Qwen3 8B Prompt Detallado	0.8138	0.8192	0.8164
Qwen3 8B Prompt Multiclase	0.4909	0.4888	0.4892


Ensemble de modelos

- Se aplicó una estrategia de ensemble por votación mayoritaria con los cuatro mejores modelos.
- En caso de empate, se seleccionó la predicción del modelo con mayor F1-score.
- El ensemble alcanzó un **F1-score** de **0.8320**, superando a tres de los modelos individuales.
- No superó al mejor modelo.

ID	Modelo 0.8382	Modelo 2 0.8224	Modelo 3 0.8137	Modelo 4 0.8121	Final pred
T1_0007	0	1	1	0	1
T1_0086	1	1	0	0	1
T1_0031	0	0	1	1	0


Análisis de errores clasificación binaria

- Mostró un buen equilibrio entre clases: **26 falsos positivos** y **31 falsos negativos**.
- Mantuvo un bajo error en la clase minoritaria (Misógina).
- En los falsos positivos, el modelo penaliza lenguaje sexualizado sin entender el contexto.
- En los falsos negativos, no detecta expresiones sutiles de desprecio o violencia emocional.



Análisis de errores clasificación multiclase

- El modelo Qwen3-8B con prompt simple obtuvo **buenos resultados en clases más representadas**.
- La clase **Violencia** solo fue detectada correctamente **en 4 de 16 casos**.
- La clase **Odio** alcanzó **6 aciertos sobre 26** ejemplos totales.
- Los errores se deben principalmente al desbalance de clases y a la ambigüedad del lenguaje.
- También influye la dificultad para distinguir matices entre categorías similares.





Participación en un reto

- Este trabajo se desarrolló en el marco del reto **MiSonGyny 2025**, dentro del workshop **IberLEF** (SEPLN 2025).
- El dataset fue proporcionado por la organización.
- Los sistemas fueron evaluados sobre un conjunto oculto (**test oficial**) por la organización.
- El sistema desarrollado obtuvo el **segundo mejor resultado en ambas tareas**, entre casi **40 equipos** participantes.

Resultados de la competición



Tarea Binaria		
1	jstoledo	0.8811
2	l2C_Vega	0.8359
3	carlosdf	0.8279
4	mapachepunk	0.8051
...	...	...
12	misongyny	0.7434
13	lastus	0.5584

Tarea Multiclase		
1	jstoledo	0.5895
2	l2C_Vega	0.5613
3	eliasurios30	0.5429
4	luisramos07	0.4946
...	...	...
8	metztli	0.4247
9	misongyny	0.4150

[Enlace oficial de resultados](#)

Conclusiones

- Los **LLMs** han demostrado ser una solución eficaz para esta tarea, superando el rendimiento de modelos basados en Transformers tradicionales.
- La metodología aplicada es **válida y robusta**, respaldada por el **2º puesto en el reto MiSonGyny 2025**.
- Se obtuvieron buenos resultados generales, aunque con margen de **mejora en las clases minoritarias**, especialmente en la tarea multiclase.
- Este tipo de tareas requiere siempre de **supervisión humana** contextual, especialmente en la moderación de lenguaje sensible.

Trabajo futuro

- Ampliar el sistema a otros discursos de odio en letras de canciones, como racismo u homofobia.
- Aplicar técnicas de **data augmentation** o generación de ejemplos sintéticos para mejorar el rendimiento en clases minoritarias.
- Incorporar un sistema de **validación colaborativa**, donde los usuarios indiquen si están de acuerdo con la predicción.
- Recolectar nuevas anotaciones humanas para **reentrenar el modelo** y **adaptarlo a distintos estilos** o géneros musicales.



Reproducibilidad del trabajo

- **Dataset/:** Conjuntos de datos de entrenamiento y test utilizados en ambas tareas.
- **Cuadernos/:** Cuadernos de entrenamiento y evaluación de modelos (DeepSeek-R1, LLaMA 3.1, Qwen3).
- **Resultados/:** Archivos de predicción y resultados finales enviados a la competición.
- **Demo/:** Código de la aplicación desarrollada con Gradio.

Misogyny Detection in Song Lyrics using Large Language Models

Antonio Toro Jaén – Trabajo de Fin de Grado – Grado en Ingeniería Informática



Este repositorio contiene el trabajo realizado para el Trabajo de Fin de Grado "Detección y Clasificación de Discursos Misóginos en Letras de Canciones con Deep Learning" presentado en la competición MiSonGyny 2025 (IberLEF).



Universidad
de Huelva

Repositorio: github.com/atoroj/Misogyny-Lyrics-Detection-LLMs

I2C-UHU at MiSonGyny 2025: Fine-Tuned LLM Approach to Detect Misogyny in Spanish Song Lyrics

Antonio Toro-Jaén, Victoria Pachón-Alvarez, Jacinto Mata-Vázquez and Angel Barroso-Romero

I2C Research Group, University of Huelva, Spain

Abstract

This work presents the approach developed by the I2C Research Group for the MiSonGyny 2025 shared task at IberLEF 2025, which focused on the detection of misogynistic content in Spanish-language song lyrics. The main contribution consists in the use of prompt-based fine-tuning applied to large language models (LLMs), combined with a parameter-efficient adaptation using LoRA. For Task 1 (binary classification), several LLMs were evaluated and integrated into an ensemble model based on majority voting, with tie-breaking performed using cumulative F1-scores. For Task 2 (multiclass classification), a single model was fine-tuned to classify lyrics into four categories of misogynistic content. The proposed system was evaluated on both tasks, achieving F1-scores of 83.59% and 56.13%, respectively, and obtaining the second-best results in both cases.

Keywords

Large language models (LLMs), LoRA, Ensemble, Prompt-based fine-tuning, Misogynistic content,

1. Introduction

Detecting hate speech in online and cultural content is a growing challenge in natural language processing (NLP), especially when such content is embedded in creative forms like music. Song lyrics, in particular, present complex linguistic constructions, figurative language, and subtle messages making it particularly difficult to accurately detect misogynistic messages. Music has a strong influence on public perceptions and social dynamics. When misogynistic language is present in lyrics, it can contribute to the reinforcement and normalization of harmful gender stereotypes. Identifying and addressing such content is therefore essential to promote more inclusive and respectful representations.

This paper describes our participation in the MiSonGyny 2025 [1] task at IberLEF 2025 [2], focused on the detection of misogynistic content in Spanish-language song lyrics. The task was divided into two subtasks: Task 1, which involved binary classification (misogynistic vs. not related), and Task 2, which required multiclass classification of the type of misogynistic expression (sexualization, violence, hate, or not related).

Recent advances in Large Language Models (LLMs) [3] and prompt-based training [4] have opened new possibilities for adapting models to highly contextual and nuanced tasks. This paper presents our participation in MiSonGyny 2025, where we applied LLM-based techniques to address both subtasks of the challenge.

2. Related Works

Recent studies have shown that song lyrics can reinforce gender-based stereotypes and sexist attitudes. As music is a widely consumed cultural product, the messages embedded in lyrics may influence social perceptions of gender roles. In recent years, researchers have applied natural language processing (NLP) techniques to detect sexism and bias in lyrics and to measure their evolution over time.

A notable example is the work by Casanovas-Buliart (2024) [5], who conducted a large-scale analysis of over 2,800 of the most-listened-to songs in Spain from 1960 to 2022. They used supervised machine

IberLEF 2025, September 2025, Zaragoza, Spain

✉ antonio.toro@alu.uhu.es (A. Toro-Jaén); vpachon@dti.uhu.es (V. Pachón-Alvarez); mata@dti.uhu.es (J. Mata-Vázquez); angel.barroso880@alu.uhu.es (A. Barroso-Romero)

© 2025 Copyright for this paper by its authors. Use permitted under Creative Commons License Attribution 4.0 International (CC BY 4.0).

Artículo científico

- Este trabajo ha dado lugar a un artículo científico.
- Se describe la metodología empleada y los resultados obtenidos.
- Será publicado en el CEUR-WS.



Presentación en workshop

- Presentación en un workshop
- Enfocado en metodologías aplicadas a las ciencias sociales

Proyecto PID2021-123983OB-I00

MINISTERIO DE CIENCIA, INNOVACIÓN Y UNIVERSIDADES
Cofinanciado por la Unión Europea
AGENCIA ESTATAL DE INVESTIGACIÓN

Grupo de Investigación
E6 Estudios Sociales
Intervención Social
30 AÑOS 1996-2025

CISCOALAB
Laboratorio de Ciencias Sociales Computacionales Aplicadas
Applied Computational Social Sciences Lab

FACULTAD DE TRABAJO SOCIAL

asociación andaluza de sociología

coideso
Pensamiento Contemporáneo e Innovación para el Desarrollo Social

Narratives & Social Changes
International Research Group

KISKA
CENTRO DE INVESTIGAÇÃO EM SISTEMAS ORIENTADOS AO ALUNO

CONICET
Universidad Nacional de Mar del Plata

I N H U S

ciep|ue

**IV International Workshop on
Methodological Advances and Applications
in Social Sciences: Quantitative, Qualitative
and Computational Strategies**

12, 19 y 20 - Junio 2025
Universidad de Huelva y Zoom

#30Aniversario @GrupoESEIS
eventos.uhu.es

Muchas Gracias

02 de julio de 2025

Demo

